

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI TP. HỒ CHÍ MINH



BÁO CÁO TỔNG KẾT
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN

**Hướng dẫn về Suy Luận Biến Thiên và Mạng nơ-ron trong xấp xỉ
Không Gian Ẩn**
**(A Guide to Variational Inference and Neural Networks for
Approximating Latent Spaces)**

Mã số : KHSV725-001

Chủ nhiệm đề tài : TRƯƠNG ĐỖ VƯƠNG

Thời gian thực hiện : Từ tháng 02/2025 đến tháng 07/2025

Thành phố Hồ Chí Minh, tháng 7 năm 2025

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI TP. HỒ CHÍ MINH



BÁO CÁO TỔNG KẾT
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN

**Hướng dẫn về Suy Luận Biến Thiên và Mạng nơ-ron trong xấp xỉ
Không Gian Ẩn**
**(A Guide to Variational Inference and Neural Networks for
Approximating Latent Spaces)**

Mã số : KHSV725-001

Chủ nhiệm đề tài : Trương Đỗ Vương

Thời gian thực hiện : Từ tháng 03/2025 đến tháng 07/2025

Thành phố Hồ Chí Minh, tháng 7 năm 2025

Mục lục

LỜI CAM ĐOAN

LỜI CẢM ƠN

DANH SÁCH HÌNH VẼ

DANH SÁCH BẢNG

DANH SÁCH BẢNG CHỮ CÁI VIẾT TẮT

MỞ ĐẦU	1
1 Tính cấp thiết của đề tài	1
2 Phạm vi nghiên cứu	2
3 Phương pháp nghiên cứu	2
4 Cơ sở khoa học và ý nghĩa thực tiễn của đề tài	2
5 Các nội dung nghiên cứu chính của đề tài	3
1 SUY LUẬN BIẾN THIÊN	4
1 Cơ Sở Nền Tảng cho Suy Luận Biến Thiên	4
1.1 Định lý Bayes	4
1.2 Phân kỳ KL (Kullback–Leibler Divergence)	5
1.2.1 Trường hợp biến ngẫu nhiên rời rạc	5
1.2.2 Trường hợp biến ngẫu nhiên liên tục	5
1.2.3 Trường hợp tổng quát	5
1.2.4 Đặc điểm của KL Divergence	5
1.2.5 Forward KL và Reverse KL Divergence	5
1.3 Luật số lớn (Law of Large Numbers)	6
2 Minh Họa cho Suy Luận Biến Thiên: Dẫn Dắt Vấn Đề	6
2.1 Biến quan sát x	6
2.2 Không gian ẩn z	7
2.3 Mối quan hệ giữa x và z	7
2.4 Mối quan hệ giữa z và x	8
2.5 Kết luận	9
3 Lựa chọn hàm khả năng - likelihood $p(x z)$	10
3.1 Minh họa trực quan	10
3.2 Các lựa chọn phổ biến cho $p(x z)$	10
3.3 Vai trò của hàm khả năng	11
4 Phân phối tiên nghiệm $p(z)$	11

4.1	Minh họa trực quan	11
4.2	Các lựa chọn cho phân phối tiên nghiệm	12
4.3	Vai trò của tiên nghiệm trong suy luận	12
5	Xấp xỉ Phân phối Hậu nghiệm: Khó khăn và Lựa chọn KL Divergence	12
5.1	Khó khăn trong việc tính toán phân phối hậu nghiệm $p(z x)$	13
5.2	Xấp xỉ phân phối hậu nghiệm bằng phân phối $q(z x)$	13
5.3	Đo lường sự khác biệt giữa $q(z x)$ và $p(z x)$ bằng KL Divergence	13
5.4	Lý do chọn Reverse KL Divergence trong Suy luận Biến thiên	13
5.5	Kết luận:	14
6	Phương pháp Suy luận biến thiên	14
6.1	Phân tích KL Divergence: Bước đầu trong Suy luận Biến thiên	14
6.2	Từ KL Divergence đến Cận dưới bằng chứng (ELBO)	15
6.3	Khai triển ELBO: Phân tích thành phần và ý nghĩa	16
6.4	Kết luận về ELBO	16
7	Minh họa cho Suy Luận Biến Thiên: Góc Nhìn Trực Quan	17
7.1	Nhắc lại về minh họa trước	17
7.2	Suy Luận Biến Thiên	17
7.3	Bằng chứng $p_\theta(x)$	18
7.4	Cận dưới bằng chứng (ELBO)	18
7.5	Tổng kết	19
2	XẤP XỈ VÀ PHÂN TÍCH KHÔNG GIAN ẨN BẰNG MÔ HÌNH VAE	20
1	Ứng dụng của Suy Luận Biến Thiên: Tự động hóa Biến Thiên (VAE)	20
2	Cơ Sở Nền Tảng cho mô hình Tự động hóa Biến Thiên	20
2.1	Suy Luận Biến Thiên (Variational Inference) — Tóm Tắt Nhanh	20
2.2	Nền tảng Deep Learning - Tổng Quan	21
3	Đặt vấn đề	21
4	Bộ tự mã hóa (Autoencoder)	21
4.1	Kiến trúc cơ bản	22
4.2	Cơ chế hoạt động	22
4.3	Ứng dụng và hạn chế	23
4.3.1	Ứng dụng	23
4.3.2	Hạn chế	23
5	Bộ mã hóa tự động biến thiên(VAE)	23
5.1	Mối quan hệ giữa VAE và VI	23
5.1.1	Lựa chọn phân phối tiên nghiệm: $p_\theta(z)$	24
5.1.2	Lựa chọn phân phối xấp xỉ: $q_\phi(z x)$	24
5.1.3	Lựa chọn hàm khả năng (likelihood): $p_\theta(x z)$	24
5.1.4	Tóm lại	24
5.2	Mẹo tái tham số (Reparameterization Trick)	25
5.3	Cận dưới bằng chứng (ELBO) trong VAE	26
5.3.1	Lỗi tái cấu trúc	26
5.3.2	Phân kỳ KL	26
5.3.3	Tổng hợp	26
6	Xây dựng và đánh giá mô hình Autoencoder và Variational Autoencoder	27
6.1	Siêu tham số và kiến trúc trên không gian ẩn 32D	27
6.2	Hàm mất mát và tối ưu	28

6.3	Kết quả huấn luyện	28
6.3.1	Đánh giá đầu ra được tái cấu trúc	28
6.3.2	Một số cách khắc phục:	29
6.4	Trực quan hóa không gian ẩn (Latent space) bằng UMAP	29
6.5	Minh họa quá trình lấy mẫu của Autoencoder và Variational Autoencoder trên không gian ẩn 2D	30
6.5.1	Siêu tham số và Kiến trúc với hệ không gian ẩn 2 chiều	30
6.5.2	Trực quan hóa không gian ẩn 2 chiều của AE và VAE	31
6.5.3	Tái cấu trúc dữ liệu từ không gian ẩn	32
6.5.4	Không gian ẩn chứa đặc trưng của dữ liệu	33
3	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN CỦA ĐỀ TÀI	34
1	Kết luận	34
2	Hướng phát triển của đề tài	34
	DANH MỤC TÀI LIỆU THAM KHẢO	36

Lời cam đoan

Tôi xin cam đoan báo cáo khoa học này là kết quả của quá trình học tập và nghiên cứu nghiêm túc do chính tôi thực hiện. Các dữ liệu, hình ảnh, bảng biểu và kết quả phân tích trong báo cáo được trình bày trung thực, có nguồn gốc rõ ràng, không sao chép từ bất kỳ công trình nào khác.

Tôi hoàn toàn chịu trách nhiệm về tính trung thực và tính khoa học của nội dung báo cáo.

TP. Hồ Chí Minh, Ngày 15 Tháng 07 Năm 2025

Sinh viên thực hiện

(ký và ghi rõ họ tên)

Lời cảm ơn

Em xin trân trọng cảm ơn Ban Lãnh đạo Viện, Ban Tổ chức Hội nghị Sinh viên nghiên cứu khoa học đã tạo cơ hội cho em được trình bày kết quả nghiên cứu của mình tại hội nghị năm nay.

Em xin bày tỏ lòng biết ơn sâu sắc đến các thầy cô, bạn bè và các đơn vị đã hỗ trợ, tạo điều kiện thuận lợi để em hoàn thành nghiên cứu này.

Kính chúc Hội nghị Sinh viên nghiên cứu khoa học thành công tốt đẹp!
Trân trọng.

TP. Hồ Chí Minh, Ngày 15 Tháng 07 Năm 2025

Sinh viên thực hiện
(ký và ghi rõ họ tên)

Danh sách hình vẽ

1.1	Minh họa về sự khác biệt giữa Forward KL và Reverse KL (trích từ [1][Jang, 2016]) . . .	6
1.2	Đồ thị DAG, biểu diễn mối quan hệ giữa x và z phỏng theo [2][Ganguly and Earp, 2021]	7
1.3	Minh họa mối quan hệ giữa x và z bằng hàm số $f(x)$	8
1.4	Minh họa mối quan hệ giữa x và z bằng hàm phân phối xác suất $p(x z)$	9
1.5	Hàm khả năng có thể là hàm phân phối xác suất $p(x z)$ hoặc hàm số $f(z) = x$	9
1.6	Mối quan hệ đầy đủ giữa x và z được mô tả bằng các hàm phân phối xác suất.	10
1.7	Minh họa cho hàm khả năng - likelihood $p(x z)$	11
1.8	Minh họa vai trò của phân phối tiên nghiệm $p(z)$ trong mô hình suy luận ẩn.	12
1.9	Biểu diễn sơ đồ của phân phối hậu nghiệm thực $P(Z X)$ (bên trái) và phân phối xấp xỉ $Q(Z X)$ (bên phải) được sử dụng để xấp xỉ nó. Mục tiêu (ở giữa) của phương pháp suy luận biến thể là tìm ra phân phối xấp xỉ $Q(Z X)$ sao cho $p_\theta(z x) \approx q_\phi(z x)$, từ đó giúp chúng ta có thể ước lượng phân phối hậu nghiệm thực một cách hiệu quả.	17
1.10	Mối quan hệ giữa Cận dưới bằng chứng (ELBO) và mục tiêu của bài toán: Tối đa hóa ELBO tương đương với tối thiểu hóa phân kỳ KL, điều đó tương đương với việc tối đa hóa $\mathbb{E}_{q_\phi(z x)} [\log p_\theta(x z)]$ và tối thiểu hóa $D_{\text{KL}}(q_\phi(z x) \parallel p_\theta(z))$	19
2.1	Cấu trúc Bộ tự mã hóa với hai phần: Encoder, Decoder	22
2.2	Minh họa cho cả VAE dưới Mẹo tái tham số (Reparameterization Trick)	25
2.3	(a) AE – kết quả huấn luyện	28
2.4	(b) VAE – Kết quả huấn luyện	28
2.5	Kết quả huấn luyện của AE và VAE trên 100 epochs: (a) $\frac{1}{2}\text{SSE}$ của AE; (b) ELBO của VAE.	28
2.6	(a) AE – Hàng trên: dữ liệu đầu vào; Hàng dưới: dữ liệu tái cấu trúc.	28
2.7	(b) VAE – Hàng trên: dữ liệu đầu vào; Hàng dưới: dữ liệu tái cấu trúc.	28
2.8	So sánh kết quả tái cấu trúc giữa Autoencoder (AE) và Variational Autoencoder (VAE).	28
2.9	(a) AE – UMAP từ latent 32D xuống 2D	29
2.10	(b) VAE – UMAP từ latent 32D xuống 2D	29
2.11	So sánh trực quan không gian ẩn 32D của AE và VAE sau khi giảm chiều với UMAP.	29
2.12	Không gian ẩn 2 chiều của AE sau khi huấn luyện	31
2.13	Không gian ẩn 2 chiều của VAE sau khi huấn luyện	31
2.14	Minh họa về phân phối chuẩn nhiều chiều (Multivariate normal distribution)	31
2.15	(a) AE – từ điểm latent quan sát được	32
2.16	(b) AE – điểm latent nằm ngoài tập quan sát	32
2.17	(c) VAE – từ điểm latent quan sát được	32
2.18	(d) VAE – điểm latent nằm ngoài tập quan sát	32

2.19 Ví dụ mẫu tái cấu trúc từ không gian ẩn: (a),(b) với Autoencoder và (c),(d) với Variational Autoencoder. Hàng trên là mẫu từ các điểm latent đã quan sát, hàng dưới là mẫu từ các điểm latent ngoại biên.	32
2.20 Lấy mẫu liên tục từ một phần của không gian ẩn với $z_1 \in (-2, 2)$ và $z_2 \in (0, 2)$	33

Danh sách bảng

2.1	So sánh siêu tham số và kiến trúc của AE và VAE (32D latent)	27
2.2	Hàm mất mát và bộ tối ưu của AE và VAE	28
2.3	So sánh siêu tham số và kiến trúc của AE và VAE (2D latent)	30

Danh sách bảng chữ cái viết tắt

STT	TỪ VIẾT TẮT	TỪ TIẾNG ANH	DỊCH NGHĨA
1	VI	Variational Inference	Suy luận biến thiên
2	AE	Autoencoder	Bộ mã tự động
3	VAE	Variational Autoencoder	Bộ mã tự động biến thiên
4	KL	Kullback–Leibler Divergence	Phân kỳ Kullback–Leibler
5	ELBO	Evidence Lower Bound	Cận dưới bằng chứng
6	IWAE	Importance Weighted Autoencoder	Bộ mã tự động với trọng số quan trọng
7	CVAE	Conditional Variational Autoencoder	Bộ mã tự động biến thiên có điều kiện
8	GAN	Generative Adversarial Network	Mạng đối kháng nghịch sinh
9	UMAP	Uniform Manifold Approximation and Projection	Phép xấp xỉ và chiếu không gian đa tạp
10	DAG	Directed Acyclic Graph	Đồ thị có hướng vô chu trình
11	RE	Reconstruction Error	Lỗi tái cấu trúc
12	MSE	Mean Squared Error	Lỗi bình phương trung bình
13	SSE	Sum of Squared Errors	Tổng bình phương sai số
14	$\frac{1}{2}$ SSE	Half Sum of Squared Errors	Nửa tổng bình phương sai số
15	ADAM	Adaptive Moment Estimation	Thuật toán tối ưu hoá Adam
16	MNIST	Modified National Institute of Standards and Technology	Tập dữ liệu chữ số viết tay MNIST

Lời mở đầu

Không gian ẩn là thành phần cốt lõi để biểu diễn và mô hình hóa dữ liệu phức tạp, chứa đựng những đặc trưng quan trọng của dữ liệu trong không gian có chiều thấp hơn. Bài hướng dẫn này cung cấp một cái nhìn trực quan, dễ hiểu về Suy Luận Biến Thiên (Variational Inference) [2][Ganguly and Earp, 2021], một phương pháp sử dụng các phân phối xác suất để xấp xỉ không gian ẩn. Qua việc trình bày, giải thích và giới thiệu các khái niệm then chốt như phân kỳ Kullback–Leibler (KL divergence) [3][Kullback and Leibler, 1951] và Cận dưới bằng chứng (Evidence Lower Bound) [4][Kingma and Welling, 2013], kèm theo các minh họa thực tiễn và việc áp dụng VI qua mô hình học sâu VAE [4][Kingma and Welling, 2013], người đọc sẽ có được cái nhìn tổng quan về cách tiếp cận bài toán không gian ẩn cũng như nhận thức được tầm quan trọng của VI trong việc giải quyết các bài toán học máy hiện đại.

1 Tính cấp thiết của đề tài

Trong bối cảnh hiện đại, khi mà khối lượng dữ liệu ngày càng gia tăng và có tính phức tạp cao, việc biểu diễn và mô hình hóa dữ liệu trở thành một thách thức lớn đối với lĩnh vực học máy. Một trong những hướng đi hiệu quả là việc sử dụng không gian ẩn để trích xuất các đặc trưng chính của dữ liệu, giúp giảm chiều không gian và tăng cường khả năng khai thác các thông tin quan trọng.

Trong bài viết này, chúng ta sẽ cùng tìm hiểu về khái niệm không gian ẩn cũng như áp dụng phương pháp Suy Luận Biến Thiên (Variational Inference - VI) để xấp xỉ không gian ẩn, qua đó mở ra những hướng ứng dụng tiềm năng trong các mô hình như Variational Auto-Encoder (VAE). Bài viết hướng tới việc cung cấp một cái nhìn tổng quan, dễ hiểu về lý thuyết lẫn thực tiễn của VI, cũng như những thách thức và lợi ích khi áp dụng vào bài toán học máy hiện đại.

Trong bối cảnh hiện nay, cùng với sự phát triển mạnh mẽ của ngành Công nghệ Thông tin – đặc biệt là lĩnh vực khoa học dữ liệu và trí tuệ nhân tạo, các yêu cầu về việc hiểu và khai thác không gian ẩn (latent space) trong các mô hình học sâu ngày càng trở nên cấp thiết. Những hạn chế về khả năng diễn giải (interpretability) và hiệu quả xấp xỉ phân phối hậu nghiệm trong các mô hình như Variational Autoencoder (VAE) đòi hỏi cần có những hướng dẫn rõ ràng, trực quan nhằm giúp cả người mới bắt đầu và nhà nghiên cứu tiếp cận nhanh với các khái niệm then chốt như KL Divergence, ELBO, reparameterization trick... Đề tài “Hướng dẫn về Suy Luận Biến Thiên và Mạng nơ-ron trong xấp xỉ Không Gian Ẩn” ra đời nhằm lấp đầy khoảng trống về tài liệu dạng tutorial – vốn rất hiếm trong tiếng Việt, đồng thời đóng góp cơ sở khoa học để triển khai và áp dụng Variational Inference vào các bài toán thực tế. Chính vì vậy, nghiên cứu này mang tính cấp thiết cả về mặt lý luận lẫn thực tiễn.

2 Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu các khái niệm nền tảng và phương pháp chính của Suy Luận Biến Thiên (Variational Inference) cũng như ứng dụng của nó trong mô hình Variational Autoencoder (VAE), bao gồm:

- Định nghĩa và đặc tính của KL Divergence (forward/reverse).
- Cơ sở lý thuyết về ELBO và cách khai triển.
- Mẹo tái tham số (Reparameterization trick) trong VAE.
- Kiến trúc cơ bản và ví dụ minh họa trên dữ liệu mở.

Phạm vi không bao gồm các phương pháp nâng cao như Normalizing Flows, Bayesian Neural Networks hay các ứng dụng phức tạp trên tập dữ liệu lớn thực tế. Các yếu tố ngoài phạm vi như tối ưu nâng cao (AdamW, Ranger), fine-tuning trên GPU phân tán hay benchmark với CIFAR-10, ImageNet sẽ không được xem xét trong báo cáo này.

3 Phương pháp nghiên cứu

Để xây dựng tutorial này, tác giả đã sử dụng:

- **Phương pháp khảo sát thực tiễn:** Thu thập và tổng hợp các bài báo, giáo trình và khoá học uy tín về Variational Inference, VAE [4][Kingma and Welling, 2013] [2][Ganguly and Earp, 2021], ...
- **Phương pháp phân tích – tổng hợp:** Phân tích chi tiết từng bước toán học (ELBO, KL Divergence), sau đó tổng hợp thành các minh hoạ trực quan bằng đồ thị và ví dụ cụ thể.
- **Phương pháp mô phỏng:** Xây dựng các đoạn code Python đơn giản để trực quan hoá latent space bằng UMAP hoặc trên không gian hai chiều (2D), so sánh quá trình tái cấu trúc giữa Autoencoder và VAE.

4 Cơ sở khoa học và ý nghĩa thực tiễn của đề tài

- **Cơ sở khoa học:**
 - Dựa trên nguyên lý Bayes và định lý Bayes trong suy luận xác suất;
 - Nền tảng lý thuyết về KL Divergence và Luật số lớn để xấp xỉ kỳ vọng;
 - Các nguyên lý deep learning về mạng nơ-ron feed-forward, cơ chế encoding-decoding.
- **Ý nghĩa thực tiễn:**
 - Giúp sinh viên và những ai quan tâm nắm vững các khái niệm then chốt của Variational Inference một cách trực quan.
 - Là tài liệu tham khảo để triển khai mô hình VAE trong các bài toán giảm chiều, tạo sinh dữ liệu và trực quan hóa không gian ẩn.
 - Đóng góp nền tảng để mở rộng sang các kỹ thuật nâng cao như Beta-VAE, Conditional VAE, trong các ứng dụng thực tế như thị giác máy tính, xử lý ngôn ngữ tự nhiên.

5 Các nội dung nghiên cứu chính của đề tài

Cấu trúc báo cáo được chia thành 3 chương, cụ thể như sau:

- **Chương 1: Suy Luận Biến Thiên** Nội dung chương 1 bao gồm cơ sở nền tảng về Suy Luận Biến Thiên: định lý Bayes, phân kỳ Kullback–Leibler (KL Divergence) với các trường hợp rời rạc và liên tục, Luật số lớn và mô hình hóa phân phối hậu nghiệm. Khai triển khái niệm Evidence Lower Bound (ELBO) và cơ chế reparameterization trick.
- **Chương 2: Xấp xỉ và phân tích không gian ẩn bằng mô hình VAE** Chương 2 trình bày kiến trúc Autoencoder truyền thống và lý thuyết về VAE: lựa chọn phân phối tiên nghiệm $p(z)$, hàm likelihood $p(x | z)$, phân phối xấp xỉ $q(z | x)$. Mô hình chi tiết, huấn luyện và thực nghiệm trên latent space (2D và 32D), đánh giá lỗi tái cấu trúc (reconstruction error), ELBO, và trực quan hóa latent space bằng UMAP.
- **Chương 3: Kết luận và hướng phát triển của đề tài** Chương 3 tổng kết kết quả nghiên cứu, đánh giá ưu–nhược điểm, khẳng định đóng góp của tutorial và đề xuất hướng phát triển như áp dụng biến thể VAE (IWAE, β -VAE, Normalizing Flows), Conditional VAE, kết hợp VAE với GAN/Transformer và triển khai trên dữ liệu thực tế.

Chương 1

SUY LUẬN BIẾN THIÊN

1 Cơ Sở Nền Tảng cho Suy Luận Biến Thiên

Phần này nhằm giới thiệu những khái niệm nền tảng giúp người đọc chuẩn bị kiến thức cần thiết cho Suy Luận Biến Thiên. Ở đây, chúng ta sẽ đề cập đến:

- Định lý Bayes.
- Phân kỳ KL (KL Divergence) [3][Kullback and Leibler, 1951].
- Forward KL và Reverse KL [3][Kullback and Leibler, 1951].
- Luật số lớn (Law of Large Numbers).

1.1 Định lý Bayes

Định lý Bayes là nền tảng của suy luận xác suất, cho biết cách cập nhật niềm tin (phân phối tiên nghiệm) dựa trên dữ liệu quan sát được. Cụ thể, với biến ẩn z và dữ liệu x , định lý Bayes được phát biểu dưới dạng:

$$p(z | x) = \frac{p(x | z) p(z)}{p(x)} \quad (1.1)$$

với:

- $p(z | x)$: phân phối hậu nghiệm của biến ẩn z khi biết x .
- $p(x | z)$: hàm khả năng (likelihood) cho dữ liệu x với điều kiện z .
- $p(z)$: phân phối tiên nghiệm (prior) của z .
- $p(x)$: chứng cứ (evidence), tính bằng:

$$p(x) = \int p(x | z) p(z) dz \quad (\text{cho biến liên tục}) \quad (1.2)$$

$$p(x) = \sum_z p(x | z) p(z) \quad (\text{cho biến rời rạc}) \quad (1.3)$$

1.2 Phân kỳ KL (Kullback–Leibler Divergence)

KL Divergence đo lường mức độ khác biệt giữa hai phân phối xác suất, từ đó là công cụ trọng yếu để so sánh sự chênh lệch giữa phân phối thực và phân phối xấp xỉ (hoặc giữa phân phối hậu nghiệm và phân phối xấp xỉ trong mô hình Bayesian).

1.2.1 Trường hợp biến ngẫu nhiên rời rạc

Với biến ngẫu nhiên rời rạc có không gian mẫu $\mathcal{X}$ và hai phân phối $p(x)$ và $q(x)$, KL Divergence được định nghĩa là:

$$D_{\text{KL}}(p \parallel q) = \sum_{x \in \mathcal{X}} p(x) \log \frac{p(x)}{q(x)} \quad (1.4)$$

1.2.2 Trường hợp biến ngẫu nhiên liên tục

Nếu $p(x)$ và $q(x)$ là hàm mật độ của hai phân phối xác suất liên tục trên không gian mẫu $\mathcal{X}$, ta có:

$$D_{\text{KL}}(p \parallel q) = \int_{\mathcal{X}} p(x) \log \frac{p(x)}{q(x)} dx \quad (1.5)$$

1.2.3 Trường hợp tổng quát

Ở dạng tổng quát nhất, ta có thể định nghĩa KL Divergence của hai phân phối p và q (có thể là rời rạc hoặc liên tục) thông qua kỳ vọng:

$$D_{\text{KL}}(p \parallel q) = \mathbb{E}_p \left[\log \frac{p(x)}{q(x)} \right] \quad (1.6)$$

trong đó kỳ vọng $\mathbb{E}_p$ được tính theo phân phối p . Công thức này tổng hợp cả hai trường hợp trên.

1.2.4 Đặc điểm của KL Divergence

- $D_{\text{KL}}(p \parallel q) \geq 0$, và đạt giá trị 0 khi và chỉ khi $p(x) = q(x)$ với mọi $x \in \mathcal{X}$.
- KL Divergence không đối xứng, tức nói chung:

$$D_{\text{KL}}(p \parallel q) \neq D_{\text{KL}}(q \parallel p) \quad (1.7)$$

1.2.5 Forward KL và Reverse KL Divergence


Do tính không đối xứng của KL Divergence, thứ tự của các phân phối trong định nghĩa sẽ mang lại các góc nhìn khác nhau:

- **Forward KL:** $D_{\text{KL}}(p \parallel q)$

Trong ngữ cảnh này, p thường được coi là phân phối “chính” (hoặc phân phối dữ liệu) và q là phân phối xấp xỉ. Forward KL ưu tiên bao trùm toàn bộ các khu vực mà p có khối lượng xác suất lớn, từ đó có xu hướng phủ các mode của p .

- **Reverse KL:** $D_{\text{KL}}(q \parallel p)$

Ở đây, q là phân phối xấp xỉ và p là phân phối thật. Reverse KL thường “chọn lọc”, tập trung vào các vùng mà q có xác suất cao và bỏ qua các vùng có xác suất thấp của p ; đặc tính này gọi là “mode-seeking”.



Hình 1.1: Minh họa về sự khác biệt giữa Forward KL và Reverse KL (trích từ [1][Jang, 2016])

1.3 Luật số lớn (Law of Large Numbers)

Một giải pháp cơ bản để xấp xỉ kỳ vọng của một hàm số là dựa trên Luật số lớn. Cụ thể, khi thực hiện một số lượng lớn các lần thử nghiệm, trung bình mẫu của các giá trị thu được sẽ hội tụ về kỳ vọng của hàm số đó theo phân phối:

$$\frac{1}{N} \sum_{i=1}^N h(x_i) \approx \mathbb{E}_p[h(X)], \quad \text{với } N \text{ đủ lớn.} \quad (1.8)$$

Luật số lớn đảm bảo rằng với số mẫu lớn, trung bình các giá trị quan sát được hội tụ về kỳ vọng thực sự của hàm $h(X)$ theo phân phối $p(x)$. Đây là cơ sở lý thuyết giúp ta sử dụng các phương pháp lấy mẫu để xấp xỉ tích phân và kỳ vọng trong các bài toán thống kê, đặc biệt quan trọng trong Variational Inference.

2 Minh Họa cho Suy Luận Biến Thiên: Dẫn Dắt Vấn Đề

Hãy tưởng tượng rằng bạn là một bác sĩ tâm lý. Một ngày, bạn gặp một bệnh nhân đang cảm thấy buồn bã và trầm cảm. Bạn muốn giúp người bệnh vượt qua trạng thái khó khăn đó, vì vậy bạn hỏi:

"Tại sao bạn cảm thấy như vậy?"

Tuy nhiên, bệnh nhân cũng không nhận thức được nguyên nhân gốc rễ của cảm xúc của mình. Nhiệm vụ của bạn trở nên khó khăn hơn khi cả hai đều chưa biết rõ nguyên nhân chính xác.

Trong bối cảnh này, các khái niệm về **biến quan sát** và **không gian ẩn** sẽ đóng vai trò then chốt:

2.1 Biến quan sát x


x là dữ liệu hay dấu hiệu mà bạn có thể thu thập được trực tiếp từ bệnh nhân. Trong trường hợp bác sĩ tâm lý, x biểu thị cho các biểu hiện bên ngoài như lời nói, hành vi, ánh mắt, v.v. Những thông tin này là những “dữ liệu quan sát được” nhưng chỉ cho thấy bề nổi, không tiết lộ ngay nguyên nhân sâu xa gây ra tâm trạng của bệnh nhân.

2.2 Không gian ẩn z

z là các biến ẩn chứa những thông tin cốt lõi, nguyên nhân gốc rễ mà không thể đo lường trực tiếp. Trong ví dụ của bác sĩ tâm lý, z đại diện cho những yếu tố bên trong như quá khứ, áp lực nội tâm, những trải nghiệm không thể hiện ngay với người ngoài, v.v.

2.3 Mối quan hệ giữa x và z


Nói cách khác, nếu ta coi mối quan hệ giữa nguyên nhân và biểu hiện theo dạng:



Hình 1.2: Đồ thị DAG, biểu diễn mối quan hệ giữa x và z phỏng theo [2][Ganguly and Earp, 2021]

thì x là kết quả quan sát được qua một quá trình phức tạp phụ thuộc vào z . Do z là các yếu tố tiềm ẩn không được đo lường trực tiếp, nhiệm vụ của chúng ta là "tìm ra" một mô hình toán học để diễn tả mối quan hệ giữa x và z , **từ đó tìm ra nguyên nhân z từ hệ quả x** . Tuy nhiên, việc xác định một

mô hình cụ thể cho mối quan hệ giữa z và x không phải là điều đơn giản. Giả sử ta cố gắng mô hình hóa mối quan hệ này bằng một hàm số đơn giản như sau:




Hình 1.3: Minh họa mối quan hệ giữa x và z bằng hàm số $f(x)$

Trong biểu thức này, ta ngụ ý rằng mỗi biểu hiện x có một nguyên nhân duy nhất z . Nhưng trên thực tế, điều này không phản ánh đúng bản chất của các hiện tượng phức tạp như tâm lý con người. Một biểu hiện buồn bã của bệnh nhân (tức một giá trị cụ thể của x) có thể do nhiều nguyên nhân khác nhau gây ra: mất việc, tổn thương thời thơ ấu, thiếu ngủ, hoặc một căn bệnh về thần kinh. Tức là, có thể có nhiều giá trị z khác nhau đều có khả năng sinh ra cùng một giá trị x . Do đó, phương trình $z = f(x)$ là quá đơn giản và không đủ để diễn tả tính không xác định, tính đa nguyên nhân (multi-causality) của thực tế.

Một cách tiếp cận khác là mô hình hóa x như kết quả của một tập hợp các nguyên nhân tiềm ẩn:

$$z = \{z_1, z_2, z_3, \dots, z_n\}, \quad x = f(z_1, z_2, \dots, z_n)$$



Trong đó mỗi z_i là một yếu tố tiềm ẩn khác nhau (ví dụ: stress, di truyền, dinh dưỡng, môi trường sống, ...). Mô hình này giàu biểu hiện hơn, cho phép nhiều nguyên nhân kết hợp để sinh ra một biểu hiện quan sát được. Nhưng một câu hỏi thực tế lại xuất hiện:

"Chúng ta cần bao nhiêu biến z_i ? Và mỗi biến có ý nghĩa gì?"


Trong thực tế, không ai có thể liệt kê và định lượng chính xác tất cả các yếu tố này.

Chính vì vậy, ta cần một mô hình linh hoạt hơn, cho phép thể hiện sự bất định và phức tạp của mối quan hệ giữa nguyên nhân và kết quả. Thay vì tìm một hàm số xác định, ta mô hình hóa mối quan hệ này bằng một phân phối xác suất:

Phân phối này cho ta biết, với mỗi quan sát x , có những khả năng nào của nguyên nhân z có thể đã gây ra biểu hiện đó. Thay vì đưa ra một giá trị duy nhất cho z hay là nhiều giá trị được định nghĩa sẵn, phân phối này cung cấp một cái nhìn toàn diện: có thể có nhiều giá trị z khả dĩ, mỗi giá trị mang một xác suất tương ứng. Đây chính là cách tiếp cận của thống kê Bayes.

2.4 Mối quan hệ giữa z và x

Qua phần trên, có lẽ bạn đã hiểu tại sao ta mô hình hóa mối quan hệ $x \rightarrow z$ bằng hàm phân phối xác suất $p(z | x)$. Vậy, còn mối quan hệ giữa $z \rightarrow x$? Trên lý thuyết ta cũng có thể mô hình hóa $z \rightarrow x$



Hình 1.4: Minh họa mối quan hệ giữa x và z bằng hàm phân phối xác suất $p(x | z)$

bằng $p(x | z)$ nhưng điểm khác biệt giữa $x \rightarrow z$ và $z \rightarrow x$ sẽ là yếu tố quyết định lựa chọn của ta về $z \rightarrow x$:

- Một kết quả (x) có thể bắt nguồn từ rất nhiều nguyên nhân (z) khác nhau.
- Trong khi đó, với đủ nhiều nguyên nhân (z) thì thường chỉ tạo ra một kết quả (x) duy nhất.

Vì thế, về mặt lý thuyết, việc đi từ x đến z ($x \rightarrow z$) sẽ **phức tạp hơn** so với đi từ z sang x ($z \rightarrow x$).


- Do đó, khi xây dựng mô hình, ta thường định nghĩa trước cách tạo ra x từ z , tức là chọn một dạng phân phối $p(x | z)$ cố định.
- Lý do là trong thực tế, chúng ta “biết” quá trình nguyên nhân $\rightarrow$ kết quả, nên chỉ cần tập trung vào $p(z | x)$ vì nó phức tạp hơn $p(x | z)$ rất nhiều.

"Chúng ta thường cho rằng đã biết cách tính được hàm khả năng (likelihood) $P(X | Z)$ " -

"We usually assume that we know how to compute functions on likelihood function $P(X | Z)$ "

Jang et al. (2016)[1][Jang, 2016]

Do đó, ta cũng có thể lựa chọn cách tiếp cận mối quan hệ $z \rightarrow x$ bằng phương trình $f(z) = y$ hoặc hàm phân phối xác suất $p(x | z)$.



Hình 1.5: Hàm khả năng có thể là hàm phân phối xác suất $p(x | z)$ hoặc hàm số $f(z) = x$


2.5 Kết luận

Phân phối hậu nghiệm $p(z | x)$ đóng vai trò then chốt trong các mô hình suy luận ẩn, đặc biệt trong phương pháp **Suy luận biến thiên (Variational Inference)**. Chính phân phối này giúp chúng ta trả lời những câu hỏi quan trọng như:

- Với một hành vi hay lời nói cụ thể (được ký hiệu là x), thì các nguyên nhân tiềm ẩn (ký hiệu z) có thể là gì?

- Trong số những nguyên nhân khả dĩ, nguyên nhân nào có khả năng cao nhất góp phần tạo nên biểu hiện x ?
- Mức độ không chắc chắn của mô hình về mỗi nguyên nhân đó là bao nhiêu?

Qua đó, ta nhận thấy rằng việc mô hình hóa bài toán bằng các hàm phân phối xác suất là cần thiết, nhằm nắm bắt được toàn bộ các yếu tố ẩn gây ra hiện tượng quan sát được. Tổng kết lại, ta có đồ thị dưới đây:



Hình 1.6: Mối quan hệ đầy đủ giữa x và z được mô tả bằng các hàm phân phối xác suất.

3 Lựa chọn hàm khả năng - likelihood $p(x | z)$

Khi đã có giả thuyết về nguyên nhân tiềm ẩn z , bước tiếp theo là chọn *hàm khả năng* $p(x | z)$ — mô tả cách mà mỗi giá trị z cho ra các quan sát x .

3.1 Minh họa trực quan

- Nếu $z = \text{stress}$, bác sĩ có thể quan sát tần suất lời nói uể oải hoặc mất tập trung cao hơn so với bình thường, tức là $p(x = \text{uể oải} | z = \text{stress})$ lớn hơn.
- Ngược lại, với $z = \text{di truyền}$, các biểu hiện tâm lý có thể ổn định hơn, do đó các xác suất tương ứng khác nhau giữa các giá trị x .

3.2 Các lựa chọn phổ biến cho $p(x | z)$

- **Gaussian (liên tục):** phù hợp với dữ liệu thực, giả sử

$$p(x | z) = \mathcal{N}(x; \mu_\theta(z), \sigma_\theta^2(z)) \quad (1.9)$$

thường dùng khi dữ liệu gần phân phối chuẩn.

- **Bernoulli (nhị phân):** khi $x \in \{0, 1\}$, ví dụ kiểm tra có triệu chứng hay không:

$$p(x | z) = \text{Bernoulli}(x; \pi_\theta(z)) \quad (1.10)$$

với $\pi_\theta(z) = P(x = 1 | z)$.

- **Categorical (đa nhị phân):** cho x rời rạc nhiều nhãn:

$$p(x | z) = \text{Categorical}(x; p_{1:K}(z)) \quad (1.11)$$

với $p_i(z) = P(x = i | z)$ và $\sum_i p_i = 1$.

- **Poisson (đếm):** khi $x \in \mathbb{N}$ biểu thị số lần xuất hiện của triệu chứng:


$$p(x | z) = \frac{\lambda_{\theta}(z)^x e^{-\lambda_{\theta}(z)}}{x!} \quad (1.12)$$

dùng cho dữ liệu đếm.

- **Các lựa chọn khác:** Exponential, Gamma, Beta, tùy tính chất và phân bố dữ liệu quan sát được.

3.3 Vai trò của hàm khả năng

- **Mô phỏng quá trình sinh dữ liệu:** Chọn đúng $p(x | z)$ giúp mô hình phản ánh chính xác cơ chế sinh ra x từ z .
- **Tương thích với loại dữ liệu:** Khớp kiểu phân phối với đặc tính của tập quan sát (liên tục, nhị phân, đếm, v.v.) để tối ưu hóa hiệu quả học.



Hình 1.7: Minh họa cho hàm khả năng - likelihood $p(x | z)$

4 Phân phối tiên nghiệm $p(z)$

Trong minh họa của bác sĩ tâm lý, trước khi gặp bệnh nhân và thu thập bất cứ quan sát x nào, chúng ta thường đã có sẵn trong đầu một số giả thuyết về nguyên nhân tiềm ẩn z . Ví dụ 2.3:

“Nguyên nhân có thể là stress công việc, di truyền, dinh dưỡng kém, môi trường sống căng thẳng, v.v.”

Những giả thuyết ban đầu này chính là *phân phối tiên nghiệm* $p(z)$: nó biểu diễn niềm tin (prior belief) của bác sĩ về nguyên nhân z trước khi thấy các biểu hiện x .

4.1 Minh họa trực quan

- Nếu bác sĩ biết đa số bệnh nhân trầm cảm do stress, ông có thể cho $p(z = \text{stress})$ cao hơn so với các nguyên nhân khác.
- Ngược lại, nếu ở quần thể này có tiền sử gia đình cao, $p(z = \text{di truyền})$ sẽ được đánh giá cao.

Ví dụ minh họa:

$$p(z) = \begin{cases} 0.4, & z = \text{stress} \\ 0.3, & z = \text{di truyền} \\ 0.2, & z = \text{dinh dưỡng} \\ 0.1, & z = \text{môi trường} \end{cases} \quad (1.13)$$

4.2 Các lựa chọn cho phân phối tiên nghiệm


Tùy theo mức độ hiểu biết ban đầu, bác sĩ (hoặc nhà thiết kế mô hình) có thể chọn:

- **Uniform prior:** Khi không có thông tin, khởi tạo $p(z)$ đều cho mọi nguyên nhân.
- **Empirical prior:** Dựa trên tần suất quan sát từ dữ liệu tiền sử (ví dụ, tỉ lệ stress/chứng trầm cảm).
- **Structured prior:** Sử dụng phân phối chuẩn đa biến (Gaussian) hoặc hỗn hợp Gaussian để biểu diễn mối quan hệ giữa các yếu tố ẩn (ví dụ, stress và di truyền có thể tương quan).

4.3 Vai trò của tiên nghiệm trong suy luận

Khi kết hợp với phân phối hậu nghiệm $p(z | x)$, phân phối tiên nghiệm $p(z)$ sẽ đóng vai trò “điều chuẩn”, giúp:

1. Hạn chế các nguyên nhân bất thường không mong muốn.
2. Kết hợp hài hòa giữa kiến thức ban đầu và bằng chứng mới từ quan sát.



Hình 1.8: Minh họa vai trò của phân phối tiên nghiệm $p(z)$ trong mô hình suy luận ẩn.

5 Xấp xỉ Phân phối Hậu nghiệm: Khó khăn và Lựa chọn KL Divergence

Như đã minh họa ở phần dẫn dắt vấn đề, mục tiêu của ta là tìm ra phân phối hậu nghiệm $p(z | x)$ – tức là mô tả các nguyên nhân tiềm ẩn z gây ra biểu hiện x . Tuy nhiên, do tính phức tạp của mô hình (chẳng hạn mẫu số $p(x)$ trong định lý Bayes) mà tính toán trực tiếp $p(z | x)$ trở nên không khả thi, ta đề xuất sử dụng một phương pháp xấp xỉ, ký hiệu là $q(z | x)$, để thay thế. Phân phối $q(z | x)$ thường được chọn từ các họ phân phối đơn giản (ví dụ: Gaussian) với các tham số được điều chỉnh sao cho xấp xỉ tốt nhất phân phối thật $p(z | x)$.

5.1 Khó khăn trong việc tính toán phân phối hậu nghiệm $p(z | x)$

Mặc dù $p(z | x)$ cung cấp thông tin đầy đủ về các nguyên nhân tiềm ẩn z dựa trên các quan sát x , việc tính toán trực tiếp phân phối này thông qua định lý Bayes là rất khó khăn. Cụ thể, theo định lý Bayes ta có:

$$p(z | x) = \frac{p(x | z)p(z)}{p(x)} = \frac{p(x | z)p(z)}{\int p(x | z)p(z) dz} \quad (1.14)$$

Ở đây, mẫu số $p(x)$ là tích phân của $p(x | z)p(z)$ qua toàn bộ không gian ẩn z . Khi không gian z có nhiều chiều hoặc khi $p(x | z)$ mang tính phức tạp, việc tính tích phân này trở nên không khả thi hoặc tốn kém về mặt tính toán. Do đó, việc tính trực tiếp $p(z | x)$ là bất khả thi trong nhiều trường hợp thực tế.

5.2 Xấp xỉ phân phối hậu nghiệm bằng phân phối $q(z | x)$

Để khắc phục hạn chế trên, phương pháp Suy luận Biến thiên (Variational Inference) sử dụng một phân phối xấp xỉ $q(z | x)$ thay cho $p(z | x)$. Phân phối này thường được chọn từ một họ phân phối có cấu trúc đơn giản (ví dụ: Gaussian), do đó dễ lấy mẫu và tính toán. Mục tiêu là tối ưu các tham số của $q(z | x)$ sao cho sự khác biệt giữa $q(z | x)$ và $p(z | x)$ là nhỏ nhất.

5.3 Đo lường sự khác biệt giữa $q(z | x)$ và $p(z | x)$ bằng KL Divergence

Khi cần đo lường sự khác biệt giữa hai phân phối $q(z | x)$ và $p(z | x)$, ta có thể dùng Kullback-Leibler (KL) Divergence. Cụ thể, ở đây ta quan tâm đến *Reverse KL*:

$$D_{KL}(q(z | x) \| p(z | x)) = \int q(z | x) \log \frac{q(z | x)}{p(z | x)} dz \quad (1.15)$$

KL Divergence ở đây đo lường thông tin mất mát khi sử dụng $q(z | x)$ để xấp xỉ $p(z | x)$. Giá trị KL càng nhỏ, phân phối $q(z | x)$ càng gần với phân phối thật $p(z | x)$.

5.4 Lý do chọn Reverse KL Divergence trong Suy luận Biến thiên

Trong quá trình tối ưu hóa, có hai cách định nghĩa KL Divergence:

- **Forward KL:** $D_{KL}(p(z | x) \| q(z | x))$
- **Reverse KL:** $D_{KL}(q(z | x) \| p(z | x))$.

Trong bối cảnh xấp xỉ phân phối hậu nghiệm, Reverse KL Divergence thường được chọn vì các lý do sau:

- **Tính khả thi trong tính toán:** Reverse KL dựa trên tích phân theo $q(z | x)$ – phân phối mà ta dễ kiểm soát, mẫu được dễ dàng sinh ra.
- **Tính chất "mode-seeking":** Reverse KL có xu hướng tập trung vào những vùng có xác suất cao trong $q(z | x)$ và bỏ qua các vùng mà $p(z | x)$ có xác suất thấp. Điều này giúp $q(z | x)$ tập trung vào các mode của $p(z | x)$.
- **Hiệu quả trong tối ưu hóa:** Reverse KL tránh trường hợp $q(z | x)$ phân bổ xác suất vào các vùng mà $p(z | x)$ gần như bằng không, từ đó cải thiện hiệu quả quá trình tối ưu.

- **Cho phép sử dụng nhiều phân phối $q(z | x)$ để xấp xỉ $p(z | x)$:** Đối với các mô hình có phân phối $p(z | x)$ phức tạp hoặc đa mode, ta có thể huấn luyện nhiều phân phối $q(z | x)$ (ví dụ, các Gaussian với tham số khởi tạo khác nhau) để bao phủ các vùng có khối lượng xác suất cao của $p(z | x)$.

5.5 Kết luận:

Như vậy, do các hạn chế về tính khả thi khi tính trực tiếp $p(z | x)$, việc xấp xỉ bằng $q(z | x)$ là thiết yếu trong ứng dụng các phương pháp suy luận ẩn. Reverse KL Divergence là thước đo hiệu quả để đánh giá khoảng cách giữa $q(z | x)$ và $p(z | x)$, từ đó giúp tối ưu hóa phân phối xấp xỉ sao cho càng gần với phân phối thật. Đây là bước nền tảng quan trọng mở đường cho việc áp dụng Suy luận Biến thiên (Variational Inference) trong các bài toán học máy hiện đại.

6 Phương pháp Suy luận biến thiên

Mục tiêu tối thượng của ta là tìm ra $p(x | z)$; tuy nhiên, trong thực tế, ta không thể tính trực tiếp được phân phối hậu nghiệm $p(z | x)$ do các vấn đề về tính khả thi (ví dụ: mẫu số $p(x)$ là tích phân qua toàn bộ không gian ẩn có nhiều chiều không gian hoặc quá phức tạp). Phương pháp Suy luận biến thiên (Variational Inference) ra đời nhằm giúp ta xấp xỉ $p(z | x)$ bằng một phân phối thuận tiện hơn, ký hiệu là $q(z | x)$. Điều này đồng nghĩa với việc mong muốn sự khác giữa $q(z | x)$ và $p(z | x)$ theo KL Divergence được tối ưu xuống gần như bằng 0:

$$D_{KL}(q(z | x) \| p(z | x)) \approx 0 \quad (1.16)$$

Nhưng thực tế, đẳng thức trên không thể được tính một cách trực tiếp bởi vì $p(z | x)$ không được biết rõ (hoặc không thể tính được do tính phức tạp của không gian ẩn). Mọi thứ dường như đã đến ngõ cụt khi ta không có cách nào vượt qua vấn đề này để xác định chính xác $q(z | x)$.

Nhưng mỗi khi có khó khăn, luôn có những cá nhân xuất sắc nghĩ ra cách tiếp cận vấn đề một cách tài tình. Và đó chính là động lực để ra đời Suy luận biến thiên (Variational Inference) – giải pháp khả thi giúp ta xấp xỉ $p(z | x)$ bằng cách chọn một phân phối $q(z | x)$ dễ tính toán (thường là các phân phối Gaussian) và tối ưu hóa nó sao cho khoảng cách giữa $q(z | x)$ và $p(z | x)$ (đo bằng Reverse KL Divergence) đạt giá trị càng thấp càng tốt.

6.1 Phân tích KL Divergence: Bước đầu trong Suy luận Biến thiên

Để hiểu cách Suy luận Biến Thiên giải quyết vấn đề nan giải trong việc xác định $p(z | x)$, ta sẽ khai triển các khái niệm nền tảng và mở rộng chúng. Ta bắt đầu bằng cách sử dụng định nghĩa của Reverse KL Divergence ở dạng tổng quát:

$$D_{KL}(q \| p) = \mathbb{E}_q \left[\log \frac{q(x)}{p(x)} \right] \quad (1.17)$$

Ký hiệu $\mathbb{E}_q$ cho ta biết rằng kỳ vọng được tính theo phân phối q , bởi vì ta chỉ có thể thu thập được thông tin từ q mà không thể truy cập trực tiếp vào p .

Ta ký hiệu các hàm phân phối xác suất p và q với các tham số θ và ϕ tương ứng, tức:

$$D_{KL}(q_\phi \| p_\theta) = \mathbb{E}_{q_\phi} \left[\log \frac{q_\phi(x)}{p_\theta(x)} \right] \quad (1.18)$$

Từ đó, áp dụng vào bài toán của ta, ta có:

$$D_{KL}(q_\phi(z | x) \| p_\theta(z | x)) = \mathbb{E}_{q_\phi} \left[\log \frac{q_\phi(z | x)}{p_\theta(z | x)} \right] \quad (1.19)$$

- Với hàm phân phối xấp xỉ $q_\phi(z | x)$, nếu ta chọn q là một phân phối Gaussian thì các tham số ϕ sẽ bao gồm các giá trị như μ và σ^2 .
- Trong khi đó, $p_\theta(z | x)$ (phân phối thật) có tính chất phức tạp hơn rất nhiều, do đó các tham số θ thường không thể xác định một cách trực tiếp trong thực tế.

6.2 Từ KL Divergence đến Cận dưới bằng chứng (ELBO)

$$D_{KL}((q_\phi(z | x) \| p_\theta(z | x))) = \mathbb{E}_{q_\phi} \left[\log \frac{q_\phi(z | x)}{p_\theta(z | x)} \right] \quad (1.20)$$

$$= \mathbb{E}_{q_\phi} [\log q_\phi(z | x) - \log p_\theta(z | x)] \quad (1.21)$$

$$= \mathbb{E}_{q_\phi} [\log q_\phi(z | x)] - \mathbb{E}_{q_\phi} \left[\log \frac{p_\theta(z, x)}{p_\theta(x)} \right] \quad (1.22)$$

$$= \mathbb{E}_{q_\phi} [\log q_\phi(z | x)] - \mathbb{E}_{q_\phi} [\log p_\theta(z, x)] + \mathbb{E}_{q_\phi} [\log p_\theta(x)] \quad (1.23)$$

$$= \mathbb{E}_{q_\phi} [\log q_\phi(z | x)] - \mathbb{E}_{q_\phi} [\log p_\theta(z, x)] + \int q_\phi(z | x) \log p_\theta(x) dz \quad (1.24)$$

$$= \mathbb{E}_{q_\phi} [\log q_\phi(z | x)] - \mathbb{E}_{q_\phi} [\log p_\theta(z, x)] + \log p_\theta(x) \underbrace{\int q_\phi(z | x) dz}_1 \quad (1.25)$$

$$= \mathbb{E}_{q_\phi} [\log q_\phi(z | x)] - \mathbb{E}_{q_\phi} [\log p_\theta(z, x)] + \log p_\theta(x) \quad (1.26)$$

$$D_{KL}((q_\phi(z | x) \| p_\theta(z | x))) = \mathbb{E}_{q_\phi} [\log q_\phi(z | x)] - \mathbb{E}_{q_\phi} [\log p_\theta(z, x)] + \log p_\theta(x)$$

↑
Log hợp lý cận biên
(Marginal log likelihood hay Log Evidence)

$$\Leftrightarrow \log p_\theta(x) = -\mathbb{E}_{q_\phi} [\log q_\phi(z | x)] + \mathbb{E}_{q_\phi} [\log p_\theta(z, x)] + \underbrace{D_{KL}((q_\phi(z | x) \| p_\theta(z | x)))}_{\text{Khó giải}}$$

↑
Log hợp lý cận biên

↓
*Nhưng ta biết rằng $D_{KL}((q_\phi(z | x) \| p_\theta(z | x))) \geq 0$ [2.2.4]

$$\Rightarrow \log p_\theta(x) \geq \underbrace{-\mathbb{E}_{q_\phi} [\log q_\phi(z | x)] + \mathbb{E}_{q_\phi} [\log p_\theta(z, x)]}_{\text{Evidence Lower Bound (ELBO)}} \quad (1.27)$$

Bất phương trình trên cho thấy rằng **log hợp lý cận biên** $\log p_\theta(x)$ được chặn dưới bởi biểu thức mà ta gọi là ELBO. Vì $\log p_\theta(x)$ là một hằng số không đổi, nên việc tối đa hóa ELBO tương đương với việc giảm thiểu độ lệch giữa phân phối xấp xỉ $q_\phi(z | x)$ và phân phối hậu nghiệm thực sự $p_\theta(z | x)$, tức là giảm thiểu $KL(q_\phi(z | x) \| p_\theta(z | x))$.

Điều này cung cấp một cách tiếp cận khả thi để tối ưu hóa phân phối xấp xỉ $q_\phi(z | x)$ mà không

cần tính toán trực tiếp phân phối hậu nghiệm $p_\theta(z | x)$, vốn thường không khả thi trong thực tế do tính phức tạp của không gian ẩn.

6.3 Khai triển ELBO: Phân tích thành phần và ý nghĩa

$$\text{ELBO} = -\mathbb{E}_{q_\phi}[\log q_\phi(z | x)] + \mathbb{E}_{q_\phi}[\log p_\theta(z, x)] \quad (1.28)$$

$$= -\mathbb{E}_{q_\phi}[\log q_\phi(z | x)] + \mathbb{E}_{q_\phi}[\log p_\theta(x | z)] + \mathbb{E}_{q_\phi}[\log p_\theta(z)] \quad (1.29)$$

$$= \mathbb{E}_{q_\phi}[\log p_\theta(x | z)] - \mathbb{E}_{q_\phi}[\log q_\phi(z | x)] + \mathbb{E}_{q_\phi}[\log p_\theta(z)] \quad (1.30)$$


$$= \mathbb{E}_{q_\phi}[\log p_\theta(x | z)] + \mathbb{E}_{q_\phi}[-\log q_\phi(z | x) + \log p_\theta(z)] \quad (1.31)$$

$$= \mathbb{E}_{q_\phi}[\log p_\theta(x | z)] + \mathbb{E}_{q_\phi}[-(\log q_\phi(z | x) - \log p_\theta(z))] \quad (1.32)$$

$$= \mathbb{E}_{q_\phi}[\log p_\theta(x | z)] - \mathbb{E}_{q_\phi}\left[\log \frac{q_\phi(z | x)}{p_\theta(z)}\right] \quad (1.33)$$

$$= \mathbb{E}_{q_\phi}[\log p_\theta(x | z)] - D_{KL}(q_\phi(z | x) \parallel p_\theta(z)) \quad (1.34)$$

$$\text{ELBO} = \mathbb{E}_{q_\phi}[\log p_\theta(x | z)] - D_{KL}(q_\phi(z | x) \parallel p_\theta(z))$$



6.4 Kết luận về ELBO

Qua khai triển ở trên, ta có được công thức cuối cùng cho ELBO:

$$\text{ELBO} = \mathbb{E}_{q_\phi}[\log p_\theta(x | z)] - D_{KL}(q_\phi(z | x) \parallel p_\theta(z)) \quad (1.35)$$

Mục tiêu của việc Suy luận Biến thiên là tối đa hóa ELBO, tức là tìm tập hợp các tham số ϕ (cho phân phối xấp xỉ q) và θ (cho mô hình dữ liệu) sao cho:

$$\max_{\phi, \theta} \text{ELBO} = \max_{\phi, \theta} \left\{ \mathbb{E}_{q_\phi}[\log p_\theta(x | z)] - D_{KL}(q_\phi(z | x) \parallel p_\theta(z)) \right\} \quad (1.36)$$

Điều này đòi hỏi:

- $\max \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)]$: Tối đa hóa thành phần lỗi tái tạo kỳ vọng, giúp mô hình tái tạo dữ liệu x một cách chính xác từ các mẫu z được sinh ra từ $q_\phi(z | x)$.
- $\min KL(q_\phi(z | x) \parallel p_\theta(z))$: Giảm thiểu sự khác biệt giữa phân phối xấp xỉ $q_\phi(z | x)$ và phân phối tiên nghiệm $p_\theta(z)$, qua đó giúp $q_\phi(z | x)$ càng sát với cấu trúc của phân phối thực.

Do $\log p_\theta(x)$ là một hằng số đối với mỗi dữ liệu x , bất phương trình

$$\log p_\theta(x) \geq \text{ELBO} \quad (1.37)$$

luôn được thỏa mãn khi ta tối đa hóa ELBO. Qua đó, việc tăng ELBO đồng nghĩa với việc giảm thiểu $D_{KL}(q_\phi(z | x) \parallel p_\theta(z | x))$, giúp ta gián tiếp tối ưu hóa phân phối xấp xỉ $q_\phi(z | x)$ sao cho gần với phân phối hậu nghiệm thực $p_\theta(z | x)$.

Vậy, quá trình tối ưu ELBO được biểu diễn dưới dạng:

$$\max_{\phi, \theta} \text{ELBO} = \max_{\phi, \theta} \left\{ \underbrace{\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x|z)]}_{\text{Tối đa hóa lỗi tái tạo}} - \underbrace{D_{KL}(q_\phi(z|x) \parallel p_\theta(z|x))}_{\text{Giảm thiểu sự chênh lệch phân phối}} \right\} \quad (1.38)$$

7 Minh họa cho Suy Luận Biến Thiên: Góc Nhìn Trực Quan

Đọc giả có thể bỏ qua phần này(8) nếu cảm thấy ổn với Suy Luận Biến Thiên.


Phần này là tổng kết cho tất cả những gì đã đề cập ở trên, với mong muốn giúp đọc giả có được cái nhìn trực quan bằng cách diễn giải một cách dễ hiểu các công thức toán học trong Suy luận Biến Thiên (Variational Inference) nói chung và cụ thể là Cận dưới bằng chứng (Evidence Lower Bound - ELBO) nói riêng.

7.1 Nhắc lại về minh họa trước

Với nhiệm vụ là một bác sĩ tâm lý, bạn đứng trước thách thức trong việc tìm ra những nguyên nhân tiềm ẩn z dẫn đến bệnh (ví dụ: trạng thái trầm cảm hay lo âu) ở bệnh nhân. Bạn nhận ra rằng việc sử dụng hàm phân phối xác suất $p(z|x)$ để mô hình hóa mối quan hệ giữa các nguyên nhân ẩn z và các biểu hiện x là một hướng đi lý tưởng từ góc nhìn thực tế.

7.2 Suy Luận Biến Thiên

Thực tế, bạn nhanh chóng nhận ra rằng việc tìm $p(z|x)$ là không khả thi bởi vì $p(z|x)$ là một phân phối xác suất vô cùng phức tạp, với khả năng chứa vô số thông tin liên quan đến các yếu tố ẩn. Nhận thấy điều đó, bạn nghĩ đến việc sử dụng Suy Luận Biến Thiên, một phương pháp cho phép ta xấp xỉ $p(z|x)$ bằng cách lựa chọn một hoặc nhiều hàm phân phối xác suất thuận tiện hơn, ký hiệu là $q(z|x)$. Để đảm bảo rằng $q(z|x)$ xấp xỉ chính xác $p(z|x)$ nhất có thể, ta cần đánh giá khoảng cách giữa chúng. Ở đây, ta dùng Kullback–Leibler Divergence (KL Divergence), và cụ thể là Reverse KL Divergence, để đo lường sự chênh lệch giữa hai phân phối.



Hình 1.9: Biểu diễn sơ đồ của phân phối hậu nghiệm thực $P(Z|X)$ (bên trái) và phân phối xấp xỉ $Q(Z|X)$ (bên phải) được sử dụng để xấp xỉ nó. Mục tiêu (ở giữa) của phương pháp suy luận biến thể là tìm ra phân phối xấp xỉ $Q(Z|X)$ sao cho $p_\theta(z|x) \approx q_\phi(z|x)$, từ đó giúp chúng ta có thể ước lượng phân phối hậu nghiệm thực một cách hiệu quả.

7.3 Bằng chứng $p_\theta(x)$

Vì ta không có cách tính trực tiếp $p(z | x)$, nên hiển nhiên cũng không thể tính được trực tiếp KL Divergence giữa $q(z | x)$ và $p(z | x)$. Để tìm ra giải pháp, ta khai triển KL Divergence và được:

$$D_{KL}(q_\phi(z | x) \| p_\theta(z | x)) = \mathbb{E}_{q_\phi(z|x)}[\log q_\phi(z | x)] - \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(z | x)] + \log p_\theta(x) \quad (1.39)$$

Trong đó, $p_\theta(x)$ được gọi là bằng chứng (evidence). Dưới góc nhìn của một ví dụ minh họa, bạn có thể hiểu rằng: $p_\theta(x)$ là hàm xác suất thống kê được tính toán dựa trên tất cả các tham số có thể, và do đó $p_\theta(x)$ là một hằng số (hoặc chân lý) không thay đổi đối với mỗi dữ liệu x . Từ đó, khi ta cố gắng tối đa hóa ELBO, tức là làm lớn nhất về bên phải (được gọi là ELBO), thì do $\log p_\theta(x)$ không đổi, KL Divergence phải giảm xuống để bất phương trình luôn được thỏa mãn. Đây chính là cách gián tiếp mà ta tối ưu hóa mục tiêu tối thượng của mình: làm cho KL Divergence càng nhỏ càng tốt.

7.4 Cận dưới bằng chứng (ELBO)

Từ đó, ta khai triển được công thức của *Cận dưới bằng chứng* (Evidence Lower Bound - ELBO) như sau:

$$\text{ELBO} = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)] - D_{KL}(q_\phi(z | x) \| p_\theta(z)) \quad (1.40)$$

Cách diễn giải công thức này:

- $\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)]$: Đây là **lỗi tái tạo kỳ vọng**, biểu thị khả năng mô hình tái tạo dữ liệu x từ biến ẩn z . Thành phần $p_\theta(x | z)$ ở đây được định nghĩa trong mô hình sinh dữ liệu mà ta xây dựng. Vì ta tự thiết kế mô hình sinh $p_\theta(x | z)$ (chẳng hạn, với các giả định như phân phối Gaussian, Bernoulli, v.v...), nên giá trị của $p_\theta(x | z)$ được xác định một cách rõ ràng theo kiến thức tiên nghiệm và cấu trúc mô hình.
- $D_{KL}(q_\phi(z | x) \| p_\theta(z))$: Đây là **phân kỳ KL** giữa phân phối xấp xỉ $q_\phi(z | x)$ và phân phối tiên nghiệm $p_\theta(z)$. Trong phần mô hình, $p_\theta(z)$ được giả định là phân phối tiên nghiệm cho biến ẩn z . Lựa chọn phân phối tiên nghiệm này thường dựa trên những giả định hợp lý (ví dụ: phân phối chuẩn $\mathcal{N}(0, I)$) để đơn giản hóa quá trình tính toán cũng như biểu diễn kiến thức ban đầu về z .

Phải hiểu rằng, cả $p_\theta(x | z)$ và $p_\theta(z)$ đều là các thành phần trong mô hình được định nghĩa bởi người xây dựng mô hình. Những thành phần này được lựa chọn dựa trên hiểu biết về dữ liệu và qua đó đưa ra những giả định hợp lý để có thể ước lượng và tối ưu hóa mô hình. Vì vậy, các biểu thức này được biết trước và không phải là những hằng số chưa biết, khác với $p_\theta(z | x)$ - phân phối sau khi quan sát dữ liệu x - vốn quá phức tạp và không thể tính trực tiếp.

Vì $\log p_\theta(x)$ là một hằng số đối với dữ liệu x , bất phương trình

$$\log p_\theta(x) \geq \text{ELBO} \quad (1.41)$$


luôn được thỏa mãn. Do đó, mục tiêu tối ưu của Variational Inference là:

$$\max_{\phi, \theta} \text{ELBO} = \max_{\phi, \theta} \left\{ \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)] - D_{KL}(q_\phi(z | x) \| p_\theta(z)) \right\} \quad (1.42)$$

Nói cách khác, để tối đa hóa ELBO, ta cần:

- Tối đa hóa lỗi tái tạo kỳ vọng $\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)]$, giúp mô hình có khả năng tái tạo x chính xác từ z .

- Giảm thiểu phân kỳ KL $D_{KL}(q_\phi(z | x) \parallel p_\theta(z))$, đảm bảo rằng phân phối xấp xỉ $q_\phi(z | x)$ sát với phân phối tiên nghiệm $p_\theta(z)$.



Hình 1.10: Mối quan hệ giữa Cận dưới bằng chứng (ELBO) và mục tiêu của bài toán: Tối đa hóa ELBO tương đương với tối thiểu hóa phân kỳ KL, điều đó tương đương với việc tối đa hóa $\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x | z)]$ và tối thiểu hóa $D_{KL}(q_\phi(z | x) \parallel p_\theta(z))$.

7.5 Tổng kết

Qua quá trình triển khai, chúng ta không chỉ tìm ra được cách xấp xỉ phân phối hậu nghiệm $p(z | x)$ phức tạp thông qua phân phối thuận tiện hơn $q(z | x)$, mà còn mở rộng được cách tiếp cận tối ưu hóa ban đầu của KL Divergence. Thông qua khai triển và tách các hằng số theo các thành phần, mục tiêu tối ưu trở thành việc tăng cường độ chính xác của hàm tái tạo

$$\mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x | z)] \quad (1.43)$$

đồng thời giảm thiểu khoảng cách KL giữa $q(z | x)$ và phân phối tiên nghiệm $p(z)$.

Điều đặc biệt quan trọng ở đây là, thay vì phải đối mặt trực tiếp với sự phức tạp của phân phối gốc $P(z | x)$ – nơi mà thông tin còn quá hạn chế và khó khai thác – chúng ta đã chuyển trọng tâm tối ưu sang cơ sở của $Q(z | x)$, nơi chúng ta có nhiều thông tin hơn. Qua đó, việc tối ưu hóa ban đầu của KL Divergence được thực hiện một cách gián tiếp: chúng ta sử dụng những thông tin sẵn có từ $q(z | x)$ để gián tiếp đẩy $q(z | x)$ tiến gần đến $p(z | x)$. Đây chính là sức mạnh của phương pháp Suy Luận Biến Thiên, biến một bài toán không khả thi thành một bài toán tối ưu hóa hiệu quả và khả thi, mở đường cho nhiều ứng dụng khác nhau trong học máy.

Tóm lại, quá trình khai triển không chỉ giúp chúng ta hiểu rõ hơn về mối quan hệ giữa các thành phần trong mô hình mà còn chỉ ra cách tối ưu hóa gián tiếp và hiệu quả hơn trong không gian $Q(Z | X)$, từ đó củng cố lại lý thuyết và ứng dụng của phương pháp này.

Chương 2

XẤP XỈ VÀ PHÂN TÍCH KHÔNG GIAN ẨN BẰNG MÔ HÌNH VAE

1 Ứng dụng của Suy Luận Biến Thiên: Tự động hóa Biến Thiên (VAE)

Phần tiếp theo là một ứng dụng tiêu biểu của phương pháp Suy Luận Biến Thiên–Mô hình Tự động hóa Biến Thiên (Variational Autoencoder), kết hợp mạng nơ-ron với lý thuyết xác suất để cho ra một mô hình tạo sinh.

VAE được thiết kế nhằm mục tiêu vừa học phân phối xấp xỉ hậu nghiệm $q_\phi(z | x)$, vừa tạo ra dữ liệu mới từ phân phối dữ liệu giả định $p_\theta(x)$, thông qua tối ưu Cận Dưới Bằng Chứng (ELBO).

2 Cơ Sở Nền Tảng cho mô hình Tự động hóa Biến Thiên

Trước khi đi sâu vào chi tiết Variational Autoencoder (VAE), ta cần hệ thống lại hai nền tảng chính: Suy Luận Biến Thiên (Variational Inference) và Deep Learning.

2.1 Suy Luận Biến Thiên (Variational Inference) — Tóm Tắt Nhanh

Variational Inference (VI) là phương pháp xấp xỉ phân phối hậu nghiệm $p(z | x)$ vốn rất phức tạp, bằng cách tìm một phân phối dễ tính $q_\phi(z | x)$ sao cho $KL(q_\phi(z | x) \| p(z | x))$ được tối thiểu hóa, tức là ELBO được tối đa hóa. ELBO đã được khai triển thành

$$\text{ELBO} = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)] - D_{KL}(q_\phi(z | x) \| p(z)) \quad (2.1)$$

Với sự xuất hiện của kỳ vọng $\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x | z)]$ trong công thức ELBO, đòi hỏi ta cần giải pháp hiệu quả để tính toán kỳ vọng

Theo *Luật số lớn* (Law of Large Numbers), khi lấy đủ nhiều mẫu độc lập $z_1, \dots, z_N$ từ $q_\phi(z | x)$, trung bình mẫu

$$\frac{1}{N} \sum_{i=1}^N \log p_\theta(x | z_i) \quad (2.2)$$

sẽ xấp xỉ đúng kỳ vọng đó khi N đủ lớn. sau đó ước lượng ELBO qua

$$\widehat{\text{ELBO}} = \frac{1}{N} \sum_{i=1}^N \log p_{\theta}(x | z_i) - D_{\text{KL}}(q_{\phi}(z | x) \| p(z)) \quad (2.3)$$

Qua sự cần thiết của Luật Số Lớn, có thể nói rằng: Suy Luận Biến Thiên chỉ khả thi với sức mạnh tính toán của máy tính.

2.2 Nền tảng Deep Learning - Tổng Quan

VAE là một mô hình học sâu (deep learning) kết hợp mạng nơ-ron với phương pháp VI:

- Đọc giả nên có nền tảng cơ bản về mạng nơ-ron, hàm kích hoạt, quá trình huấn luyện bằng gradient descent, và các khái niệm như overfitting, regularization.
- Chủ đề “deep learning” rất rộng và phức tạp, vì thế ta sẽ không đề cập đến các kỹ thuật như CNN, RNN hay attention, mà chỉ sử dụng các thành phần mạng feed-forward cơ bản để xây dựng VAE.

Hai nền tảng này — Suy Luận Biến Thiên trên góc độ xác suất, và các lớp mạng nơ-ron của Deep Learning — chính là cơ sở để VAE có thể học được các biểu diễn tiềm ẩn z và sinh mẫu dữ liệu mới một cách hiệu quả.

3 Đặt vấn đề


Variational Autoencoder (VAE) là một minh chứng điển hình cho việc ứng dụng phương pháp Suy luận Biến Thiên (Variational Inference) vào các mô hình sinh dữ liệu. Giống như trong ví dụ của bác sĩ tâm lý [2.2.4], nơi ta không thể “thấy” trực tiếp nguyên nhân z đằng sau các biểu hiện x nhưng lại cần hiểu và mô hình hóa chúng, VAE cũng hướng tới việc học một *không gian ẩn* (*latent space*) z sao cho nó có thể giải thích tốt nhất các quan sát x .

Một số ví dụ thực tế

- **Nhận diện chữ số:** Trong quá trình nhận thức, con người có thể dễ dàng phân biệt hình ảnh chữ số từ 0 đến 9, nhưng nguyên lý về việc tại sao nét vẽ này lại được hiểu là “3” — lại rất phức tạp và khó mô tả. Variational Autoencoder giải quyết câu hỏi này bằng cách giả định một *không gian ẩn* z , nơi các đặc trưng trừu tượng không thể quan sát trực tiếp được mã hóa, từ đó giúp mô hình vừa phân biệt được từng chữ số.
- **Vật thể trong không gian:** Khi quan sát một vật thể đang di chuyển, chúng ta nhìn thấy vị trí x tại mỗi thời điểm, nhưng không “thấy” được vận tốc v một biến ẩn có ảnh hưởng quyết định đến động lực. Tương tự, VAE cũng cố gắng để biết được biểu diễn của *không gian ẩn* z trong đó có thể bao gồm vận tốc v của vật thể, để mô hình hóa độ không chắc chắn và các khả năng khác nhau của nguyên nhân tiềm ẩn.


4 Bộ tự mã hóa (Autoencoder)

Với vấn đề đã đặt ra ở trên — ta cần một biểu diễn tiềm ẩn z sao cho từ z có thể tái tạo quan sát x một cách hiệu quả — rất dễ hình dung mối quan hệ giữa x và z như đồ thị dưới đây:



Và trong lĩnh vực học sâu (deep learning), tồn tại một mô hình mạng nơ-ron cụ thể được biết đến với chức năng tương tự, đó là Bộ tự mã hóa (Autoencoder).

4.1 Kiến trúc cơ bản



Hình 2.1: Cấu trúc Bộ tự mã hóa với hai phần: Encoder, Decoder

Cấu trúc **minh họa** của Bộ tự mã hóa bao gồm hai thành phần chính: phần nén (Encoder) và phần tái cấu trúc (Decoder). Phần nén bắt đầu với lớp đầu vào (input) có 8 nơ-ron, tiếp theo là ba lớp ẩn với số lượng nơ-ron lần lượt là 5, 5 và 4. Sau đó, dữ liệu được nén xuống lớp thắt cổ chai (bottleneck) có 2 nơ-ron, đây là lớp nén dữ liệu. Phần tái cấu trúc (Decoder) được cấu trúc ngược lại so với phần nén. Nó bắt đầu từ lớp thắt cổ chai có 2 nơ-ron, sau đó là các lớp ẩn với số lượng nơ-ron lần lượt là 4, 5, 5, và cuối cùng là lớp đầu ra (output) có 8 nơ-ron, tương ứng với lớp đầu vào của phần nén.

- **Encoder** $f_\phi: x \mapsto z$: ánh xạ dữ liệu đầu vào $\mathbf{x} \in \mathbb{R}^D$ xuống không gian tiềm ẩn $\mathbf{z} \in \mathbb{R}^d$ với $d \ll D$.
- **Decoder** $g_\theta: z \mapsto \hat{x}$: lấy $\mathbf{z}$ từ bottleneck, tái cấu trúc $\hat{\mathbf{x}} \in \mathbb{R}^D$.

Lưu ý rằng, cấu trúc đối xứng giữa encoder và decoder trong Autoencoder chỉ là một **thiết kế thường thấy** chứ không phải **quy tắc bắt buộc**.

4.2 Cơ chế hoạt động

1. **Nén (Encoding)**: Dữ liệu $\{x_1, \dots, x_8\}$ được đưa qua encoder, chỉ giữ lại hai giá trị $\{z_1, z_2\}$.
2. **Giải nén (Decoding)**: Từ $\{z_1, z_2\}$, decoder cố gắng tái tạo $\{\hat{x}_1, \dots, \hat{x}_8\}$.
3. **Mục tiêu huấn luyện**: Tối thiểu hóa hàm mất mát

$$\mathcal{L}(x, \hat{x}) = \|x - \hat{x}\|^2 \quad (\text{hoặc cross-entropy nếu } x \text{ nhị phân}) \quad (2.4)$$

Khi huấn luyện thành công, nếu:

$$\{x_1, \dots, x_8\} \approx \{\hat{x}_1, \dots, \hat{x}_8\} \quad (2.5)$$

thì hai biến z_1, z_2 đã học được có thể biểu diễn hiệu quả dữ liệu và nén giữ đủ thông tin cần thiết.

4.3 Ứng dụng và hạn chế

4.3.1 Ứng dụng

- Giảm chiều dữ liệu (dimensionality reduction), tiền xử lý cho các bài toán phân loại, phân cụm (clustering).
- Phát hiện bất thường (anomaly detection): các mẫu khó tái tạo thường là ngoại lệ.
- Khử nhiễu (denoising): nén và tái tạo giúp loại bỏ nhiễu.

4.3.2 Hạn chế

- **Không thể tạo sinh (Non-generative):** Autoencoder cổ điển không cung cấp cơ chế sinh mẫu mới từ không gian ẩn, bởi vì $z = f_\phi(x)$ là một ánh xạ xác định (deterministic). Do đó, mô hình không thể biểu diễn độ không chắc chắn (uncertainty).
- **Hệ không gian ẩn phân bố rời rạc:** Vì không có ràng buộc nào trên không gian tiềm ẩn $Z = \{z_1, z_2\}$, các mã ẩn (*latent codes*) thường phân bố một cách rời rạc và “loãng”. Nói cách khác, nếu ta chọn ngẫu nhiên một điểm z trong toàn bộ không gian ẩn, rất có thể mô hình không thể tái cấu trúc nó thành một quan sát x có ý nghĩa — tương tự như vũ trụ rộng lớn có nhiều hành tinh, nhưng hầu hết không gian giữa chúng vẫn hoàn toàn trống trải.
- **Để hiểu một cách trực quan hơn về hạn chế của Bộ tự mã hóa, bạn có thể nhìn lại [2.3], lý do tại sao ta lại chọn mô hình hóa mối quan hệ giữa x và z bằng hàm phân phối xác suất thay vì một hàm số $f_\phi(x)$ hay $g_\theta(x)$.**

Chính những hạn chế trên đã dẫn đến việc phát triển Variational Autoencoder, mở rộng Autoencoder cổ điển thành mô hình sinh mẫu có bản chất xác suất.

5 Bộ mã hóa tự động biến thiên(VAE)

Variational Autoencoder (VAE) mở rộng Bộ tự mã hóa(Autoencoder) cổ điển bằng cách thay ánh xạ xác định $z = f_\phi(x)$ thành việc học một phân phối $q_\phi(z | x)$. Mô hình kết hợp lý thuyết Suy luận Biến Thiên với mạng nơ-ron để vừa suy luận latent variable z vừa sinh mẫu mới từ $p_\theta(x)$ thông qua tối ưu Cận dưới bằng chứng (ELBO).

5.1 Mối quan hệ giữa VAE và VI

Variational Autoencoder (VAE) là một ứng dụng cụ thể của phương pháp Suy Luận Biến Thiên (VI) trong học sâu: VAE sử dụng ELBO làm hàm mục tiêu để đồng thời học mạng suy luận $q_\phi(z | x)$ và mạng sinh mẫu $p_\theta(x | z)$. Để triển khai VAE, ta cần đưa ra ba lựa chọn chính:

5.1.1 Lựa chọn phân phối tiên nghiệm: $p_\theta(z)$

VAE chọn phân phối tiên nghiệm sao cho vừa *dễ tính toán* vừa *điều chuẩn* được latent space. Thông thường, ta dùng:

$$p_\theta(z) = \mathcal{N}(0, 1) \quad (2.6)$$

vừa cho phép tính KL divergence xác định, vừa giữ cho các mã ẩn không tràn lan, loãng như trong Autoencoder cổ điển.

5.1.2 Lựa chọn phân phối xấp xỉ: $q_\phi(z | x)$

Để xấp xỉ hậu nghiệm (posterior) $p_\theta(z | x)$, VAE chọn một họ phân phối đơn giản nhưng đủ linh hoạt, thường là Gaussian, với các tham số $\mu_\phi(x)$ và $\sigma_\phi^2(x)$ là đầu ra của phần Encoder:

$$\mu_\phi(x), \quad \log \sigma_\phi^2(x) \quad (2.7)$$

Để đảm bảo rằng σ^2 luôn dương khi được học bởi mô hình (do phương sai luôn dương) không bao giờ âm) và cải thiện sự ổn định khi huấn luyện ta lấy log của σ^2 . Khi đó, chúng ta có công thức của hậu nghiệm như sau:

$$q_\phi(z | x) = \mathcal{N}(z; \mu_\phi(x), e^{\log \sigma_\phi^2(x)}) \quad (2.8)$$

$$\Leftrightarrow q_\phi(z | x) = \mathcal{N}(z; \mu_\phi(x), e^{2 \log \sigma_\phi(x)}) \quad (2.9)$$

Hoặc ta cũng có thể sử dụng Độ lệch chuẩn σ thay thì phương sai σ^2 Với:

$$\Leftrightarrow q_\phi(z | x) = \mathcal{N}(z; \mu_\phi(x), e^{\frac{1}{2} 2 \log \sigma_\phi(x)}) \quad (2.10)$$

5.1.3 Lựa chọn hàm khả năng (likelihood): $p_\theta(x | z)$

Hàm khả năng mô tả cách biến ẩn z sinh ra dữ liệu quan sát mới $\hat{x}$. Trong VAE, mặc dù về bản chất decoder là một hàm số $\hat{x} = f_\theta(z)$, ta thường giả định nó là một hàm phân phối xác suất bởi vì z được lấy mẫu từ phân phối xác suất :

Vì ta đã chọn $q_\phi(z | x)$ là hàm phân phối chuẩn $z \sim \mathcal{N}(z; \mu_\phi(x), e^{\log \sigma_\phi^2(x)})$

$$p_\theta(x | z) = f_\theta \left[\mathcal{N}(z; \mu_\phi(x), e^{\log \sigma_\phi^2(x)}) \right] \quad (2.11)$$

Lựa chọn đảm bảo rằng phần **lỗi tái cấu trúc** trong ELBO, $\mathbb{E}_{q_\phi}[\log p_\theta(x | z)]$, có thể được tính hoặc xấp xỉ hiệu quả.

5.1.4 Tóm lại

VAE thực thi VI bằng cách:

1. Chọn prior Gaussian $p(z)$ để điều chuẩn latent space.
2. Xấp xỉ hậu nghiệm (posterior) bằng phân phối chuẩn (Gaussian) $q_\phi(z | x)$.
3. Tối ưu hóa Cận Dưới Bằng Chứng ELBO.
4. Giả định likelihood phù hợp với loại dữ liệu ($\mathcal{N}$, Bernoulli, Categorical, v.v.).

Nhờ vậy, VAE vừa có thể *suy luận* (inference) về biến ẩn z từ dữ liệu x , vừa có khả năng *sinh mẫu* (generation) những quan sát mới từ prior $p(z)$.

5.2 Mẹo tái tham số (Reparameterization Trick)

Trong VAE, để ước lượng gradient của ELBO, ta cần backpropagation qua bước lấy mẫu $z \sim q_\phi(z | x)$. Tuy nhiên, nếu viết trực tiếp:

$$z \sim \mathcal{N}\left(z; \mu_\phi(x), e^{\log \sigma_\phi^2(x)}\right) \quad (2.12)$$

(ngầm hiểu rằng log có cơ số e)

Vì gradient ∇_ϕ không thể đi qua phép lấy mẫu không khả vi này.

Reparameterization Trick [4][Kingma and Welling, 2013] giải quyết vấn đề bằng cách tách phần ngẫu nhiên ra khỏi tham số ϕ . Cụ thể, ta lấy:

$$\epsilon \sim \mathcal{N}(0, I), \quad z = \mu_\phi(x) + e^{\log \sigma_\phi^2(x)} \odot \epsilon \quad (2.13)$$


trong đó ϵ không phụ thuộc vào ϕ , và các hàm $\mu_\phi(x)$, $\log \sigma_\phi^2(x)$ là khả vi.

Khi đó, ELBO trở thành:

$$\text{ELBO} = \mathbb{E}_{q_\phi(z|x)} [\log p_\theta(x | z)] - D_{\text{KL}}(q_\phi(z | x) \| p(z)) \quad (2.14)$$

$$= \mathbb{E}_{\epsilon \sim \mathcal{N}(0, I)} \left[\log p_\theta \left(x | \mu_\phi(x) + e^{\log \sigma_\phi^2(x)} \odot \epsilon \right) \right] \quad (2.15)$$

$$- D_{\text{KL}} \left(\mathcal{N}\left(z; \mu_\phi(x), e^{\log \sigma_\phi^2(x)}\right) \| \mathcal{N}(0, I) \right) \quad (2.16)$$



Hình 2.2: Minh họa cho cả VAE dưới Mẹo tái tham số (Reparameterization Trick)

5.3 Cận dưới bằng chứng (ELBO) trong VAE

Trong VAE, ELBO được xây dựng từ hai thành phần:

$$\mathcal{L}(\phi, \theta; x) = \underbrace{\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)]}_{\text{Lỗi tái cấu trúc}} - \underbrace{D_{\text{KL}}(q_\phi(z|x) \| p(z))}_{\text{Phân kỳ KL}} \quad (2.17)$$

5.3.1 Lỗi tái cấu trúc

Giả sử decoder được mô hình hoá bởi

$$p_\theta(x|z) = \mathcal{N}(x; g_\theta(z), I)$$

Khi đó,

$$\log p_\theta(x|z) = -\frac{1}{2}\|x - g_\theta(z)\|^2 - \frac{D}{2}\log(2\pi) = -\frac{1}{2}\|x - g_\theta(z)\|^2 + \text{const}$$

với $\text{const} = -\frac{D}{2}\log(2\pi)$. Phần tái cấu trúc (reconstruction term) trong ELBO là

$$\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] \propto -\mathbb{E}_{q_\phi(z|x)}[\|x - g_\theta(z)\|^2]$$

trong đó

$$\|x - g_\theta(z)\|^2 = \sum_{i=1}^D (x_i - g_\theta(z)_i)^2$$

chính là **Sum of Squared Errors (SSE)**

Trong thực tế (ví dụ PyTorch/TensorFlow), người ta thường thêm hệ số $\frac{1}{2}$ hoặc chia cho D (hoặc trung bình trên batch):

$$\text{Recon}(x, \hat{x}) = \frac{1}{2} \sum_{i=1}^D (x_i - \hat{x}_i)^2 \quad (\text{half-SSE})$$

hoặc

$$\text{MSE}(x, \hat{x}) = \frac{1}{D} \sum_{i=1}^D (x_i - \hat{x}_i)^2 \quad (\text{mean squared error})$$

Sử dụng $\frac{1}{2}$ SSE giúp gradient trở nên đơn giản (đạo hàm của $\frac{1}{2}(x - \hat{x})^2$ cho ra $x - \hat{x}$).

5.3.2 Phân kỳ KL

Giả định:

$$q_\phi(z|x) = \mathcal{N}(z; \mu_\phi(x), e^{\log \sigma_\phi^2(x)}), \quad p(z) = \mathcal{N}(0, I) \quad (2.18)$$

Ta có công thức triển khai Phân Kỳ KL[4][Kingma and Welling, 2013]:

$$D_{\text{KL}}(q_\phi \| p) = \frac{1}{2} \sum_{i=1}^d (1 + \log \sigma_{\phi,i}^2(x) - \mu_{\phi,i}^2(x) - e^{\log \sigma_\phi^2(x)}) \quad (2.19)$$

5.3.3 Tổng hợp

Tối đa hóa ELBO tương đương với tối thiểu hóa:

Lý do cho điều này là cơ chế tối ưu hóa của các mạng nơ-ron nhân tạo là cơ chế tối thiểu hóa dựa trên thuật toán Gradient Descent làm cơ sở, cho nên để áp dụng Suy Luận Biến Thiên (VI) vào mạng nơ-ron thành bộ mã hóa tự động biến thiên (VAE) thì ta cần đưa nó về bài toán tối thiểu hóa:

$$\text{ELBO} = -\mathbb{E}_{q_\phi} [\|x - g_\theta(z)\|^2] - \frac{1}{2} \sum_{i=1}^d (1 + \log \sigma_{\phi,i}^2(x) - \mu_{\phi,i}^2(x) - e^{\log \sigma_{\phi,i}^2(x)}) \quad (2.20)$$

$$\mathcal{L}_{\text{VAE}}(x) = -\text{ELBO} \quad (2.21)$$

$$\Leftrightarrow \underbrace{\frac{1}{2} \|x - g_\theta(z)\|^2}_{\frac{1}{2} \text{SSE tái cấu trúc}} + \underbrace{\frac{1}{2} \sum_{i=1}^d (e^{\log \sigma_{\phi,i}^2(x)} + \mu_{\phi,i}^2(x) - 1 - \log \sigma_{\phi,i}^2(x))}_{\text{Phân kỳ KL}} \quad (2.22)$$

6 Xây dựng và đánh giá mô hình Autoencoder và Variational Autoencoder

Phần này trình bày chi tiết quy trình thiết lập, huấn luyện và đánh giá hai mô hình mạng nơ-ron nhân tạo: Autoencoder (AE) và Variational Autoencoder (VAE) trong xấp xỉ không gian ẩn (Latent space).

Mã nguồn cho toàn bộ phần này được lưu trữ tại đường dẫn GitHub sau:

<https://github.com/zombieTDV/>

[A-Guide-to-Variational-Inference-and-Neural-Networks-for-Approximating-Latent-Spaces](#)

6.1 Siêu tham số và kiến trúc trên không gian ẩn 32D

Bảng 2.1: So sánh siêu tham số và kiến trúc của AE và VAE (32D latent)


Thuộc tính / Kiến trúc	AE	VAE
Siêu tham số		
Batch size	32	32
Learning rate (Adam)	1×10^{-3}	1×10^{-3}
Epochs	100	100
Latent dimension	32	32
Thiết bị	CUDA (nếu khả dụng)	CUDA (nếu khả dụng)
Dataset	MNIST (60k train + 10k test)	MNIST (60k train + 10k test)
Kiến trúc		
Encoder	Flatten $\rightarrow$ Linear(784, 128), ReLU $\rightarrow$ Linear(128, 32), ReLU	Flatten $\rightarrow$ Linear(784, 128), ReLU $\rightarrow$ Linear(128, 2×32)
Decoder	Linear(32, 128), ReLU $\rightarrow$ Linear(128, 784), Sigmoid $\rightarrow$ Unflatten(1, (1,28,28))	Linear(32, 128), ReLU $\rightarrow$ Linear(128, 784), Sigmoid $\rightarrow$ Unflatten(1, (1,28,28))

Bảng 2.2: Hàm mất mát và bộ tối ưu của AE và VAE


Thuộc tính	AE	VAE
Reconstruction loss	$\frac{1}{2} \sum (x - \hat{x})^2$ ($\frac{1}{2}$ SSE)	$\frac{1}{2} \sum (x - \hat{x})^2$ ($\frac{1}{2}$ SSE)
Regularization	–	$D_{KL}(\mathcal{N}(\mu, \sigma^2) \parallel \mathcal{N}(0, I)) = -\frac{1}{2} \sum (1 + \log \sigma^2 - \mu^2 - \sigma^2)$
Optimizer	Adam ($\beta_1 = 0.9$, $\beta_2 = 0.999$)	Adam ($\beta_1 = 0.9$, $\beta_2 = 0.999$)

6.2 Hàm mất mát và tối ưu

6.3 Kết quả huấn luyện



Hình 2.3: (a) AE – kết quả huấn luyện



Hình 2.4: (b) VAE – Kết quả huấn luyện

Hình 2.5: Kết quả huấn luyện của AE và VAE trên 100 epochs: (a) $\frac{1}{2}$ SSE của AE; (b) ELBO của VAE.

Quá trình huấn luyện hai mô hình cho thấy rằng VAE khó huấn luyện hơn AE; cụ thể, trong nhiều trường hợp, hệ số lỗi Train và Validation của AE có thể đến thấp nhất lần lượt là 2.9667 và 3.0374 ngược lại, VAE là 19.1487 và 19.0806 điều này cũng dễ hiểu khi hàm mất mát mà ta dùng cho VAE có thể xem là hàm mất mát của AE kết hợp với Regularization.

6.3.1 Đánh giá đầu ra được tái cấu trúc



Hình 2.6: (a) AE – Hàng trên: dữ liệu đầu vào; Hàng dưới: dữ liệu tái cấu trúc.



Hình 2.7: (b) VAE – Hàng trên: dữ liệu đầu vào; Hàng dưới: dữ liệu tái cấu trúc.

Hình 2.8: So sánh kết quả tái cấu trúc giữa Autoencoder (AE) và Variational Autoencoder (VAE).

So với Autoencoder (AE)(Hình 2.6), ảnh tái cấu trúc của Variational Autoencoder (VAE)(Hình 2.7) thường có hiện tượng mờ (blurry). Điều này xuất phát từ hai nguyên nhân chính:

- VAE sử dụng hàm mất mát SSE , $\frac{1}{2}SSE$ hoặc MSE (SSE chỉ khác MSE ở chỗ không chia trung bình) để ước lượng cho lỗi tái cấu trúc, vốn khuyến khích giá trị trung bình của tất cả các khả năng. Nói cách khác chúng đều xem trọng một cách 'công bằng' với mọi chi tiết trong dữ liệu, điều đó dẫn đến hiện tượng mất nét.

"The MSE places no weight on specific features, all features will be reconstructed with a similar weighting" [5][Bredell, Flouris, Chaitanya, Erdil and Konukoglu, 2023]


- KL divergence trong ELBO ép phân phối hậu nghiệm $p(z | x)$ về cấu trúc của tiên nghiệm $p(z)$, khiến latent space bị "nén" và decoder phải khôi phục từ không gian cô đặc, dẫn đến thiếu chi tiết. Trong minh họa trên ta lựa chọn tiên nghiệm là phân phối chuẩn tắc $\mathcal{N}(0, I)$ từ đó decoder phải phục hồi ảnh gốc từ không gian ẩn ít thông tin hơn, dẫn đến mất hoặc nhòe chi tiết.

6.3.2 Một số cách khắc phục:


1. Dùng lỗi tái cấu trúc khác như Binary Cross-Entropy (BCE) [6][Murphy, 2022].
2. Tăng độ linh hoạt của decoder (skip-connections, residual blocks) như Multi-Stage VAE[7][Cai, Gao and Ji, 2017].

6.4 Trực quan hóa không gian ẩn (Latent space) bằng UMAP

Vì không thể trực tiếp quan sát không gian ẩn đa chiều, ta sử dụng kỹ thuật "Giảm chiều UMAP" để chiếu xuống 2D cho cả AE và VAE:



Hình 2.9: (a) AE – UMAP từ latent 32D xuống 2D



Hình 2.10: (b) VAE – UMAP từ latent 32D xuống 2D

Hình 2.11: So sánh trực quan không gian ẩn 32D của AE và VAE sau khi giảm chiều với UMAP.

Nhìn chung, kết quả UMAP của cả AE và VAE đều cho thấy các cụm chữ số hội tụ rõ ràng: ví dụ dãy (9–7–4), (8–3–5) liên tục xuất hiện ở cả hai mô hình, trong khi cụm (1) đứng riêng. Điều này chứng tỏ mặc dù kiến trúc để biểu diễn latent space khác nhau, cả AE và VAE vẫn đạt hiệu quả tương đương trong việc duy trì cấu trúc phân cụm của dữ liệu.

6.5 Minh họa quá trình lấy mẫu của Autoencoder và Variational Autoencoder trên không gian ẩn 2D

Việc lấy mẫu mới từ không gian ẩn của AE là không khả thi trong thực tế và đây cũng là vấn đề mà VAE muốn khắc phục. Ta không thể lấy mẫu từ AE vì không gian ẩn của AE có thể nhận các giá trị trong khoảng $(-\infty, +\infty)$ và điều đó áp dụng cho tất cả các chiều không gian của không gian ẩn, dẫn đến việc ta không có cách nào để lấy ngẫu nhiên một vector z hợp lệ mà decoder đã từng gặp trong huấn luyện. VAE khắc phục điều này bằng cách đưa vào thành phần KL-divergence trong ELBO, ép không gian ẩn mang sắc thái của hàm phân phối xác suất; Như ở trên là phân phối chuẩn $\mathcal{N}(0, I)$ ở mọi chiều (tức phân phối chuẩn nhiều chiều, nhờ đó không gian ẩn trở nên có cấu trúc và có thể lấy mẫu trực tiếp từ $\mathcal{N}(0, I)$ để sinh dữ liệu mới. Nhờ vậy, khi muốn sinh ngẫu nhiên, ta chỉ cần lấy $z \sim \mathcal{N}(0, I)$ rồi đưa vào decoder—quá trình này vừa đơn giản vừa hiệu quả, và tạo ra các mẫu mới hợp lệ giống phân phối dữ liệu gốc.

Phần cuối cùng sau đây, sẽ minh họa cho quá trình lấy mẫu mới từ cả hai mô hình. Dưới không gian ẩn hai chiều (thích hợp cho quá trình trực quan hóa).


6.5.1 Siêu tham số và Kiến trúc với hệ không gian ẩn 2 chiều

Bảng 2.3: So sánh siêu tham số và kiến trúc của AE và VAE (2D latent)


Thuộc tính / Kiến trúc	AE	VAE
Siêu tham số		
Batch size	32	32
Learning rate (Adam)	1×10^{-3}	1×10^{-3}
Epochs	100	100
Latent dimension	2	2
Thiết bị	CUDA (nếu khả dụng)	CUDA (nếu khả dụng)
Dataset	MNIST (60k train + 10k test)	MNIST (60k train + 10k test)
Kiến trúc		
Encoder	Flatten $\rightarrow$ Linear(784, 128), ReLU $\rightarrow$ Linear(128, 2), ReLU	Flatten $\rightarrow$ Linear(784, 128), ReLU $\rightarrow$ Linear(128, 2×2)
Decoder	Linear(2, 128), ReLU $\rightarrow$ Linear(128, 784), Sigmoid $\rightarrow$ Unflatten(1, (1,28,28))	Linear(2, 128), ReLU $\rightarrow$ Linear(128, 784), Sigmoid $\rightarrow$ Unflatten(1, (1,28,28))

6.5.2 Trực quan hóa không gian ẩn 2 chiều của AE và VAE

Lần này ta có thể trực tiếp trực quan hóa không gian ẩn mà không cần thông qua UMAP vì nó chỉ bao gồm 2 chiều không gian.




Hình 2.12: Không gian ẩn 2 chiều của AE sau khi huấn luyện




Hình 2.13: Không gian ẩn 2 chiều của VAE sau khi huấn luyện

Các điểm biểu diễn của tập dữ liệu trên không gian ẩn của mô hình VAE (hình 2.13) mang sắc thái của hàm phân phối chuẩn nhiều chiều, điều này cũng cho thấy cơ sở lý thuyết của Suy Luận Biến Thiên đã được minh họa và áp dụng một cách thực tiễn. Minh họa của phân phối chuẩn nhiều chiều:




Hình 2.14: Minh họa về phân phối chuẩn nhiều chiều (Multivariate normal distribution)


6.5.3 Tái cấu trúc dữ liệu từ không gian ẩn




Hình 2.15: (a) AE – từ điểm latent quan sát được



Hình 2.16: (b) AE – điểm latent nằm ngoài tập quan sát



Hình 2.17: (c) VAE – từ điểm latent quan sát được



Hình 2.18: (d) VAE – điểm latent nằm ngoài tập quan sát


Hình 2.19: Ví dụ mẫu tái cấu trúc từ không gian ẩn: (a),(b) với Autoencoder và (c),(d) với Variational Autoencoder. Hàng trên là mẫu từ các điểm latent đã quan sát, hàng dưới là mẫu từ các điểm latent ngoại biên.

Như quan sát được, việc lấy mẫu từ không gian ẩn của **VAE** thường cho kết quả có tính nhất quán về mặt ý nghĩa hơn so với **AE**. Giải thích ngắn gọn như sau:

- **Autoencoder (AE):** AE tối ưu để giảm lỗi tái cấu trúc cho các điểm latent thu được từ dữ liệu huấn luyện. Không có ràng buộc rõ ràng nào buộc không gian latent phải có cấu trúc thuận tiện cho việc lấy mẫu ngẫu nhiên; do đó khi lấy một điểm latent chưa từng được mã hoá (ngoại biên), decoder có thể sinh ra đầu ra không tương thích (“nhiều”).
- **Variational Autoencoder (VAE):** VAE thêm một thành phần KL vào hàm mất mát để khuyến khích phân phối hậu nghiệm $q_\phi(z|x)$ gần với prior thường dùng (ví dụ $N(0, I)$). Vì vậy, các điểm được lấy từ prior có nhiều khả năng rơi vào những vùng latent mà decoder biết cách giải mã.

6.5.4 Không gian ẩn chứa đặc trưng của dữ liệu

Khi trực quan hóa không gian ẩn, ta nhận thấy các điểm dữ liệu có xu hướng phân cụm, phản ánh các đặc trưng tiềm ẩn của dữ liệu. Tuy nhiên, không gian ẩn còn chứa đựng nhiều đặc trưng khác, chẳng hạn như **vị trí tương đối** của **vật thể** trong ảnh. Để quan sát đặc trưng này, ta thực hiện việc lấy mẫu liên tục từ một phần của không gian ẩn, cụ thể với $z_1 \in (-2, 2)$ và $z_2 \in (0, 2)$.



Hình 2.20: Lấy mẫu liên tục từ một phần của không gian ẩn với $z_1 \in (-2, 2)$ và $z_2 \in (0, 2)$

Hình trên cũng minh họa khả năng của VAE trong việc sinh dữ liệu mới từ không gian ẩn. Mỗi điểm trong không gian này tương ứng với một mẫu dữ liệu có ý nghĩa, không bị nhiễu hoàn toàn. Đặc biệt, tại các vùng chuyển tiếp giữa hai phân cụm, ví dụ giữa chữ số 0 và 6, các mẫu sinh ra thể hiện đặc trưng kết hợp của cả hai, cho thấy sự chuyển đổi mượt mà giữa các đặc trưng trong không gian ẩn.

Chương 3

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN CỦA ĐỀ TÀI

1 Kết luận

Trong bài hướng dẫn này, tác giả đã trình bày một cái nhìn tổng quan và trực quan về phương pháp Suy Luận Biến Thiên (Variational Inference) và ứng dụng của nó trong mô hình Variational Autoencoder (VAE). Cụ thể, các kết quả chính bao gồm:

- Giải thích chi tiết khái niệm KL Divergence và vai trò của nó trong tối ưu hàm ELBO, giúp xấp xỉ phân phối hậu nghiệm của latent variables.
- Minh hoạ cơ chế *reparameterization trick* giúp gradient có thể lan truyền qua quá trình sampling, đảm bảo mô hình có thể huấn luyện bằng thuật toán gradient descent.
- So sánh trực quan quá trình mã hoá–giải mã của Autoencoder truyền thống và VAE, qua đó chứng minh VAE vừa duy trì khả năng tái cấu trúc tốt, vừa tạo được phân phối latent mượt mà và liên tục.
- Triển khai các ví dụ mô phỏng đơn giản (2D latent space) với Python và UMAP, giúp người đọc nắm bắt nhanh các khái niệm lý thuyết qua hình ảnh trực quan.

Những kết quả này khẳng định tính đúng đắn và tính ứng dụng cao của phương pháp VI – VAE trong việc giảm chiều dữ liệu, sinh mẫu mới và phát hiện bất thường.

2 Hướng phát triển của đề tài

Trên cơ sở nghiên cứu hiện tại, tác giả đề xuất một số hướng phát triển tiếp theo:

1. **Mở rộng kỹ thuật nâng cao:** Áp dụng các biến thể của VAE như Importance Weighted Autoencoder (IWAE) [8] [Burda, Grosse and Salakhutdinov, 2015], β -VAE [9] [Higgins, Matthey, Pal, Burgess, Glorot, Botvinick, Mohamed and Lerchner, 2017], và Normalizing Flows [10] [Papamakarios, Nalisnick, Rezende, Mohamed and Lakshminarayanan, 2019] để cải thiện chất lượng phân phối latent và khả năng tạo sinh.
2. **Ứng dụng trên dữ liệu thực tế:** Thử nghiệm với các bộ dữ liệu quy mô lớn như CIFAR-10, ImageNet để đánh giá hiệu năng và khả năng tổng quát hoá của mô hình VAE trong các bài toán nhận dạng hình ảnh.

3. **Conditional VAE và GAN kết hợp:** Nghiên cứu Conditional VAE (CVAE)[11][Harvey, Naderiparizi and Wood, 2021] cho các tác vụ phức tạp hơn (như: lấy mẫu kết hợp với nhân, thuộc tính hay các điều kiện khác ...) và kết hợp VAE với GAN để khai thác ưu điểm của cả hai phương pháp (ví dụ: VAE-GAN [12][Larsen, Sønderby, Larochelle and Winther, 2015]).
4. **Kết hợp với các kiến trúc mới:** Tích hợp VAE vào các mô hình Transformer hoặc Graph Neural Networks, nhằm mở rộng ứng dụng sang xử lý ngôn ngữ tự nhiên, phân tích dữ liệu đồ thị và các bài toán khác.
5. **Tối ưu và triển khai hệ thống:** Nghiên cứu các phương pháp tối ưu nâng cao (AdamW, ...), huấn luyện phân tán trên GPU/TPU và xây dựng thư viện mã nguồn mở để hỗ trợ cộng đồng nghiên cứu và ứng dụng nhanh chóng.

Tài liệu tham khảo

- [1]  E. Jang, *A Beginner's Guide to Variational Methods: Mean-Field Approximation*, 2016. url: <https://blog.evjang.com/2016/08/variational-bayes.html>.
- [2]  A. Ganguly and S. W. F. Earp, “An Introduction to Variational Inference,” page 2, 2021. arXiv: [2108.13083](https://arxiv.org/abs/2108.13083) [cs.LG]. url: <https://arxiv.org/abs/2108.13083>.
- [3]  S. Kullback and R. A. Leibler, “On Information and Sufficiency,” *Ann. Math. Statist.*, **journal** 22, 1951.
- [4]  D. P. Kingma and M. Welling, “Auto-Encoding Variational Bayes,” pages 3, 5–8, 2013. arXiv: [1312.6114](https://arxiv.org/abs/1312.6114) [stat.ML]. url: <https://arxiv.org/abs/1312.6114>.
- [5]  G. Bredell, K. Flouris, K. Chaitanya, E. Erdil and E. Konukoglu, “Explicitly Minimizing the Blur Error of Variational Autoencoders,” pages 1–2, 2023. arXiv: [2304.05939](https://arxiv.org/abs/2304.05939) [cs.CV]. url: <https://arxiv.org/abs/2304.05939>.
- [6]  K. P. Murphy, *Probabilistic Machine Learning: An introduction*. MIT Press, 2022, Chapter4, 107–115. url: <http://probml.github.io/book1>.
- [7]  L. Cai, H. Gao and S. Ji, “Multi-Stage Variational Auto-Encoders for Coarse-to-Fine Image Generation,” pages 3–5, 2017. arXiv: [1705.07202](https://arxiv.org/abs/1705.07202) [cs.CV]. url: <https://arxiv.org/abs/1705.07202>.
- [8]  Y. Burda, R. Grosse and R. Salakhutdinov, “Importance Weighted Autoencoders,” 2015. arXiv: [1509.00519](https://arxiv.org/abs/1509.00519) [cs.LG]. url: <https://arxiv.org/abs/1509.00519>.
- [9]  I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed and A. Lerchner, “beta-VAE: Learning Basic Visual Concepts with a Constrained Variational Framework,” in *International Conference on Learning Representations* 2017. url: <https://openreview.net/forum?id=Sy2fzU9gl>.
- [10]  G. Papamakarios, E. Nalisnick, D. J. Rezende, S. Mohamed and B. Lakshminarayanan, “Normalizing Flows for Probabilistic Modeling and Inference,” 2019. arXiv: [1912.02762](https://arxiv.org/abs/1912.02762) [stat.ML]. url: <https://arxiv.org/abs/1912.02762>.
- [11]  W. Harvey, S. Naderiparizi and F. Wood, “Conditional Image Generation by Conditioning Variational Auto-Encoders,” 2021. arXiv: [2102.12037](https://arxiv.org/abs/2102.12037) [cs.CV]. url: <https://arxiv.org/abs/2102.12037>.
- [12]  A. B. L. Larsen, S. K. Sønderby, H. Larochelle and O. Winther, “Autoencoding beyond pixels using a learned similarity metric,” 2015. arXiv: [1512.09300](https://arxiv.org/abs/1512.09300) [cs.LG]. url: <https://arxiv.org/abs/1512.09300>.